AKADEMIA GÓRNICZO-HUTNICZA IM. STANISŁAWA STASZICA W KRAKOWIE
Wydział Geologii, Geofizyki i Ochrony Środowiska

Praca inżynierska

Konrad Dąbrowski

kierunek studiów: Inżynieria i Analiza Danych

Wykorzystanie sztucznej inteligencji do analizy naruszeń praw człowieka na podstawie wskaźników społeczno-ekonomicznych

Using artificial intelligence to analyze human rights violations based on socio-economic indicators

Opiekun: dr inż. Mateusz Zaręba

Kraków, 26 stycznia 2026

Uprzedzony o odpowiedzialności karnej na podstawie art. 115 ust. 1 i 2 ustawy z dnia 4 lutego 1994 r. o prawie autorskim i prawach pokrewnych (t.j. Dz.U. z 2006 r. Nr 90, poz. 631 z późn. zm.): „ Kto przywłaszcza sobie autorstwo albo wprowadza w błąd co do autorstwa całości lub części cudzego utworu albo artystycznego wykonania, podlega grzywnie, karze ograniczenia wolności albo pozbawienia wolności do lat 3. Tej samej karze podlega, kto rozpowszechnia bez podania nazwiska lub pseudonimu twórcy cudzy utwór w wersji oryginalnej albo w postaci opracowania, artystyczne wykonanie albo publicznie zniekształca taki utwór, artystyczne wykonanie, fonogram, wideogram lub nadanie.", a także uprzedzony o odpowiedzialności dyscyplinarnej na podstawie art. 211 ust. 1 ustawy z dnia 27 lipca 2005 r. Prawo o szkolnictwie wyższym (t.j. Dz. U. z 2012 r. poz. 572, z późn. zm.) „Za naruszenie przepisów obowiązujących w uczelni oraz za czyny uchybiające godności studenta student ponosi odpowiedzialność dyscyplinarną przed komisją dyscyplinarną albo przed sądem koleżeńskim samorządu studenckiego, zwanym dalej „sądem koleżeńskim", oświadczam, że niniejszą pracę dyplomową wykonałem(-am) osobiście i samodzielnie i że nie korzystałem(-am) ze źródeł innych niż wymienione w pracy.

Data _____ Podpis _____

Spis treści

Wstęp **4**

Cel pracy **5**

Wykorzystane dane oraz narzędzia **6**
Dane 6
Narzędzia 9

Metodyka **10**
Przygotowanie danych 10
Eksploracyjna analiza danych 19
Inżynieria cech 31
Uczenie maszynowe 36

Wyniki **42**
Diagnostyka procesu optymalizacji 42
Ocena i interpretacja modelu predykcyjnego 44
Predykcja długookresowa 49

Dyskusja **54**

Podsumowanie **56**

Literatura **57**

Załączniki **60**

Wstęp

Democracy and civil liberties do not emerge by chance,
they are deeply rooted in social and economic conditions.
— Seymour Martin Lipset [1]

Prawa człowieka to zestaw powszechnych, przyrodzonych i niezbywalnych uprawnień, przysługujących każdej jednostce bez względu na jej pochodzenie czy status. Ich współczesna koncepcja zyskała formalny kształt po II wojnie światowej w Powszechnej Deklaracji Praw Człowieka z 1948 roku, która opierała się na przekonaniu o nienaruszalnej godności osoby ludzkiej [2]. Prawa te przestały być wtedy jedynie postulatem moralnym i stały się podstawą współczesnego ładu prawnego uznawanego przez społeczność międzynarodową.

W praktyce ustrojowej prawa człowieka wyznaczają nieprzekraczalną granicę dla ingerencji państwa w życie i wolność obywatela. Jak zauważa Seymour Martin Lipset, trwałość tej bariery nie jest jednak kwestią przypadku, lecz wynika z głęboko zakorzenionych uwarunkowań społecznych i ekonomicznych [1]. To spostrzeżenie stało się fundamentem nowoczesnych badań empirycznych, w których coraz częściej odchodzi się od rozważań czysto teoretycznych na rzecz analiz opartych na mierzalnych wskaźnikach rozwoju.

Systematyczna i ilościowa ocena przestrzegania praw człowieka stała się możliwa w drugiej połowie XX wieku dzięki standaryzacji metod raportowania oraz budowie międzynarodowych baz danych. Kamieniem milowym było powstanie indeksu *Freedom in the World*, który umożliwił porównywanie państw w czasie i przestrzeni, ujawniając długookresowe trendy w zakresie wolności obywatelskiej [3].

Mimo bogactwa danych dominujące nurty badawcze wciąż opierają się głównie na analizach retrospektywnych. Choć klasyczne modele statystyczne skutecznie identyfikują zależności historyczne, często zawodzą w starciu z nieliniowością procesów społecznych oraz złożonymi interakcjami wielu zmiennych jednocześnie. Problem ten precyzyjnie zdiagnozowali Ward i in. [4], wykazując, że zdolność do opisu minionych zdarzeń nie gwarantuje skutecznego przewidywania przyszłości. W efekcie obszar długookresowego prognozowania poziomu praw człowieka pozostaje niedostatecznie wyeksploatowany, co ogranicza skuteczność systemów wczesnego ostrzegania przed kryzysami humanitarnymi.

Przełom w tym zakresie przynosi dynamiczny rozwój metod sztucznej inteligencji, między innymi uczenia maszynowego. Technologie te otwierają nowe możliwości w kwantyfikacji zjawisk społecznych, pozwalając na przetwarzanie wielowymiarowych zbiorów danych i wykrywanie ukrytych wzorców, na co wskazują badania Colaresiego i Mahmooda [5]. Zastosowanie algorytmów uczenia maszynowego może stanowić brakujące ogniwo, umożliwiające przejście od opisowej analizy przeszłości do predykcyjnego modelowania przyszłości praw człowieka na świecie.

Cel pracy

Celem pracy dyplomowej jest zaprojektowanie, implementacja oraz ocena modelu uczenia maszynowego do prognozowania poziomu przestrzegania praw człowieka w państwach członkowskich Organizacji Narodów Zjednoczonych w latach 2025–2100. Ograniczenie analizy do krajów ONZ wynika z konieczności zapewnienia spójności i wysokiej jakości danych statystycznych. Wykluczenie terytoriów o nieuregulowanym statusie pozwala uniknąć luk informacyjnych, co bezpośrednio przekłada się na stabilność procesu uczenia oraz wiarygodność predykcji.

Ze względu na odległy horyzont czasowy, w badaniu wykorzystano scenariusze Wspólnych Ścieżek Społeczno-Ekonomicznych (ang. *Shared Socioeconomic Pathways – SSP*). To pięć narracji opisujących alternatywne kierunki globalnego rozwoju, które mają na celu dostarczenie spójnych ram do modelowania wpływu zmian klimatycznych, przemian demograficznych i gospodarczych na społeczeństwa. Ich szczegółową charakterystykę przedstawił zespół naukowców pod przewodnictwem Briana O'Neilla, we współpracy z Międzyrządowym Panelem ds. Zmian Klimatu (IPCC) [6]. W pracy modelowanie ograniczono do trzech scenariuszy, które wyznaczają logiczny zakres przewidywań (od progresu, przez stagnację, po regres).

I. **Scenariusz SSP1 (Zrównoważony rozwój)**
   Wariant optymistyczny, zakładający szybki wzrost poziomu edukacji, spadek nierówności i silną współpracę międzynarodową.

II. **Scenariusz SSP2 (Kontynuacja trendów)**
   Scenariusz bazowy, będący kontynuacją historycznych trendów rozwoju, gdzie postęp społeczny i polityczny następuje w dotychczasowym, umiarkowanym tempie.

III. **Scenariusz SSP3 (Rywalizacja regionalna)**
   Wariant pesymistyczny, zakładający globalną fragmentację i priorytetyzację interesów narodowych, w którym rywalizacja o zasoby wypiera współpracę międzynarodową.

Rezygnacja z pozostałych ścieżek (SSP4 i SSP5) podyktowana jest dbałością o klarowność modelu i unikanie redundancji. SSP4, opisujący specyficzne rozwarstwienie społeczne, mieści się w przedziale wartości wyznaczonym przez SSP2 i SSP3, nie wnosząc nowej charakterystyki skrajnej. Z kolei SSP5, choć opiera się na innym modelu energetycznym niż SSP1, pod względem potencjału społecznego i poziomu dobrobytu powiela jego wzorce.

Przyjęta selekcja państw i scenariuszy tworzy spójne ramy badawcze. Pozwala to na precyzyjne wyznaczenie trajektorii zmian w obszarze praw człowieka, opierając prognozy na mierzalnych parametrach rozwoju cywilizacyjnego.

Wykorzystane dane oraz narzędzia

Dane

W analizie wykorzystano dziewięć wskaźników rozwoju społeczno-ekonomicznego pełniących funkcję zmiennych objaśniających oraz miarę poziomu przestrzegania praw człowieka jako zmienną objaśnianą, określoną na podstawie wskaźnika *Freedom in the World*. W dalszej części pracy, dla uproszczenia nazewnictwa, zmienna ta będzie określana wskaźnikiem wolności.

Zmienna objaśniana

Jako miarę stanu praw człowieka przyjęto wskaźnik *Freedom in the World* publikowany przez organizację Freedom House. Składa się on z dwóch komponentów: praw politycznych (PR) oraz wolności obywatelskich (CL), ocenianych w skali od 1 do 7, gdzie niższa wartość oznacza wyższy poziom wolności. Zbiór danych obejmuje roczne oceny dla krajów i terytoriów w latach 1973–2024 [7]. Choć wskaźnik nie zlicza pojedynczych incydentów naruszeń praw człowieka, syntetyzuje ogólny stan ochrony jednostki przed represjami państwowymi, co może pozwolić wykrywać zależności między sytuacją społeczno-ekonomiczną a poziomem tej ochrony.

Zmienne objaśniające

Dobór zmiennych objaśniających wynika z założenia, że poziom praw człowieka jest wypadkową procesów demograficznych, gospodarczych, społecznych i środowiskowych. Uwzględnione wskaźniki opisują zarówno jakość instytucji publicznych, strukturę społeczną państw, jak i długookresowe uwarunkowania rozwojowe.

Wskaźnik śmiertelności niemowląt
Zmienna określa liczbę zgonów dzieci poniżej pierwszego roku życia na 1000 żywych urodzeń. Jest ona powszechnie uznawana za jeden z najbardziej czułych mierników jakości życia oraz skuteczności systemu ochrony zdrowia i administracji publicznej. W kontekście pracy stanowi pośredni wskaźnik zdolności państwa do ochrony podstawowych praw jednostki.

Wskaźnik obciążenia demograficznego osobami starszymi
Wyraża stosunek liczby osób w wieku 65+ do populacji w wieku produkcyjnym. Służy do oceny stopnia zaawansowania procesu starzenia się społeczeństwa. Wyższe wartości wskaźnika wiążą się zazwyczaj z większą stabilnością społeczną i polityczną, co sprzyja utrzymaniu instytucji demokratycznych i ogranicza ryzyko gwałtownych zmian ustrojowych.

Wskaźnik dzietności ogólnej
Określa przeciętną liczbę dzieci, które urodziłaby kobieta w całym okresie rozrodczym. W pracy traktowany jest jako pośredni miernik pozycji kobiet w społeczeństwie. Spadek dzietności historycznie wiąże się z wyższym poziomem edukacji kobiet, ich aktywnością zawodową oraz rozszerzeniem praw osobistych.

Saldo migracji netto
Zmienna definiowana jest jako różnica pomiędzy liczbą imigrantów i emigrantów. Ujemne wartości często wskazują na niestabilność polityczną lub brak perspektyw rozwojowych, natomiast dodatnie świadczą o postrzeganiu państwa jako bezpiecznego i oferującego poszanowanie praw. Stanowi istotny sygnał kondycji ustrojowej kraju.

Współczynnik maskulinizacji
Określa liczbę mężczyzn przypadających na 100 kobiet w populacji. Znaczne odchylenia od równowagi płci są statystycznie powiązane z wyższą przestępczością, przemocą i niestabilnością społeczną, a także mogą świadczyć o systemowych naruszeniach praw kobiet.

Gęstość zaludnienia
Opisuje liczbę ludności przypadającą na jednostkę powierzchni. Zmienna ta pełni funkcję kontekstową, umożliwiając różnicowanie państw o zbliżonym poziomie rozwoju, lecz odmiennej strukturze przestrzennej. Wpływa pośrednio na dostępność usług publicznych, kontrolę społeczną oraz efektywność zarządzania państwem.

Powyższe dane demograficzne pochodzą z 28. edycji *World Population Prospects 2024* opracowanej przez ONZ [8]. Zbiór obejmuje lata 1950–2023 oraz projekcje do 2100 roku, oparte na metodach probabilistycznych odzwierciedlających niepewność przyszłych trendów. ONZ nie prognozuje wskaźników w podziale na Wspólne Ścieżki Społeczno-Ekonomiczne, stosuje warianty płodności, które można powiązać z odpowiednimi ścieżkami SSP w następujący sposób:

I. **Niska Płodność → SSP1**
   Wariant zakłada, że współczynnik dzietności ogólnej pozostaje o 0.5 urodzenia poniżej wariantu średniego. Odpowiada logice SSP1, która przewiduje wysokie inwestycje w edukację i ochronę zdrowia oraz szybszą emancypację kobiet.

II. **Średnia Płodność → SSP2**
   Wariant średni stanowi medianę tysięcy trajektorii probabilistycznych. Odpowiada on scenariuszowi SSP2, który zakłada kontynuację dotychczasowych trendów rozwojowych.

III. **Wysoka Płodność → SSP3**

Wariant ten zakłada dzietność o 0.5 urodzenia wyższą niż w scenariuszu średnim. Dopasowanie do SSP3 wynika z założenia, że przy słabym wzroście gospodarczym i niskich nakładach na edukację dzietność utrzyma się na wyższym poziomie.

Należy podkreślić, że wskaźnik śmiertelności niemowląt oraz saldo migracji nie posiadają odrębnych projekcji scenariuszowych. Dla nich ONZ stosuje jednolite założenia prognostyczne, niezależne od wariantów płodności. Zbieżność tych zmiennych pomiędzy scenariuszami wynika więc z metodologii ONZ, a nie z ich rzeczywistej niewrażliwości na czynniki społeczno-ekonomiczne. Pomimo tego, zmienne zostały zachowane w modelu predykcyjnym ze względu na wysoką wartość informacyjną. Pełnią funkcję predyktorów kontrolnych, które różnicują kraje i lata w ramach danego scenariusza SSP, natomiast nie determinują różnic między scenariuszami. Takie podejście pozwala zachować spójność metodologiczną przy jednoczesnym wykorzystaniu pełnej informacji zawartej w tych wskaźnikach.

Produkt krajowy brutto per capita

Wybór tej zmiennej wynika z jej kluczowej roli w teorii modernizacji. Zgodnie z założeniami Seymoura M. Lipseta, rozwój gospodarczy tworzy podstawy stabilności procesów demokratycznych i ochrony swobód obywatelskich [1]. Miara per capita odzwierciedla średni poziom zamożności jednostki, który jest powiązany z powstawaniem klasy średniej, wyższym poziomem edukacji i odpornością społeczeństwa na autorytarne wpływy. W pracy zastosowano PKB skorygowany o Parytet Siły Nabywczej wyrażony w dolarach amerykańskich w cenach stałych z 2021 roku, co eliminuje wpływ inflacji i uwzględnia realny standard życia.

Dane pochodzą z Fundacji Gapminder [9], integrującej statystyki Banku Światowego i Międzynarodowego Funduszu Walutowego. Szeregi obejmują lata 1990–2022, a projekcje do 2100 roku oparte są na scenariuszu *„IF”*, odpowiadającym SSP2. Tempo wzrostu w latach 2023–2029 wynika z prognoz MFW, natomiast po 2030 roku model opiera się na funkcjach wielomianowych trzeciego stopnia, uwzględniających historyczną konwergencję. Najszybszy wzrost występuje w krajach o średnich dochodach, a w miarę bogacenia się dynamika spowalnia, stabilizując się w najzamożniejszych gospodarkach.

Średnia liczba lat edukacji

Zmienna odnosi się do przeciętnej liczby lat edukacji osób w wieku 25 lat i więcej. Jest kluczowa dla analizy kapitału społecznego, gdyż wyższe wykształcenie sprzyja świadomości politycznej, krytycznemu myśleniu i postawom tolerancji. Wyedukowane społeczeństwo wykazuje większą zdolność do samoorganizacji i obrony swoich praw, co utrudnia konsolidację reżimów autorytarnych i sprzyja ochronie praw mniejszości.

Dane pochodzą z *Wittgenstein Centre for Demography and Global Human Capital* [10], obejmują lata 1950–2020 oraz projekcje do 2100 roku w odstępach pięcioletnich. Część predykcyjna wykorzystuje wielostanową metodę kohortową, uwzględniającą poziom wykształcenia jako czynnik różnicujący płodność, umieralność i migracje. Projekcje są zgodne ze scenariuszami SSP.

Średnia roczna temperatura

Została włączona do analizy jako zmienna opisująca uwarunkowania geograficzne i wrażliwość na zmiany klimatu. Pozwala identyfikować regiony szczególnie narażone na stres środowiskowy, gdzie wysokie temperatury mogą zwiększać ryzyko konfliktów o zasoby naturalne oraz masowych migracji, co wpływa na stabilność państwa.

Dane pochodzą z *Climate Change Knowledge Portal* prowadzonego przez Bank Światowy, a oparte są na symulacjach szóstej fazy Projektu Porównywania Modeli Sprzężonych (CMIP6). Obejmują lata 1950–2014 (część historyczna) oraz projekcje do 2100 roku.

Dla zwiększenia rzetelności prognoz zastosowano uśrednienie wyników z trzech niezależnych modeli, które pozwala zredukować fluktuacje i uzyskać stabilniejsze projekcje zmian klimatycznych dla scenariuszy Wspólnych Ścieżek Społeczno-Ekonomicznych. Wykorzystane modele to:

- ***MPI-ESM1-2-HR*** → Instytut Meteorologii im. Maxa Plancka, Niemcy
- ***MRI-ESM2-0*** → Instytut Badań Meteorologicznych, Japonia
- ***GFDL-ESM4*** → Laboratorium Geofizycznej Dynamiki Płynów, USA

Narzędzia

W pracy używano środowiska PyCharm [11] oraz języka Python [12] do analizy danych, modelowania predykcyjnego i wizualizacji wyników. W szczególności wykorzystano następujące biblioteki: NumPy (wersja 2.1.0) [13], pandas (wersja 2.2.3) [14], SciPy (wersja 1.14.1) [15], statsmodels (wersja 0.14.4) [16], GeoPandas (wersja 1.0.1) [17], country_converter (wersja 1.2.0) [18], Matplotlib (wersja 3.9.2) [19], Seaborn (wersja 0.13.2) [20], scikit-learn (wersja 1.5.2) [21], XGBoost (wersja 2.1.1) [22], Optuna (wersja 4.1.0) [23] oraz SHAP (wersja 0.46.0) [24].

Metodyka

Przygotowanie danych

Przed rozpoczęciem właściwej analizy zmiennych przeprowadzono weryfikację kompletności wskaźnika wolności, gdyż stanowi on kluczowy parametr determinujący liczebność próby historycznej. Analizę braków oparto na komponencie swobód obywatelskich (CL), ze względu na fakt, iż rozkład brakujących danych dla tego parametru jest tożsamy z rozkładem dla komponentu praw politycznych (PR). Liczbę brakujących obserwacji w latach 1990–2012, przy ograniczeniu zbioru do państw członkowskich ONZ, przedstawiono na Rysunku 1.

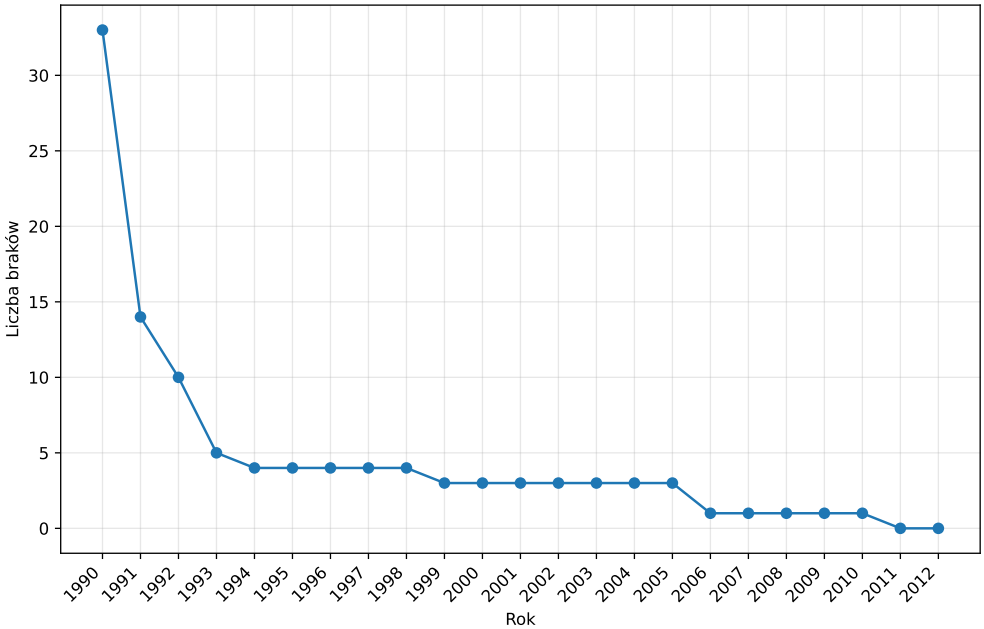

Rysunek 1: *Wykres rozkładu braków danych wskaźnika wolności w latach 1990–2012*

Liczba braków danych, która w 1990 roku wynosiła 33, spadła do 5 w roku 1993. Sytuacja ta wiąże się z procesem formowania się nowych państw na początku lat 90. XX wieku. Z punktu widzenia prognozowania szeregów czasowych, ograniczenie zbioru wyłącznie do okresu pełnej dostępności danych (2011–2024) byłoby nieuzasadnione, gdyż wiązałoby się z utratą istotnych informacji historycznych. W związku z powyższym, jako punkt początkowy dalszej analizy przyjęto rok 1993. Wybór ten stanowi optymalny kompromis pomiędzy dążeniem do maksymalizacji długości szeregu czasowego a koniecznością zapewnienia wysokiej jakości danych wejściowych.

Analiza braków danych

Szczegółowa analiza zmiennej objaśnianej wykazała, że w zbiorze występują luki dla pięciu państw: Timoru Wschodniego, Czarnogóry, Palau, Serbii oraz Sudanu Południowego. Rozkład braków danych dla wymienionych krajów przedstawiono na rysunku 2.

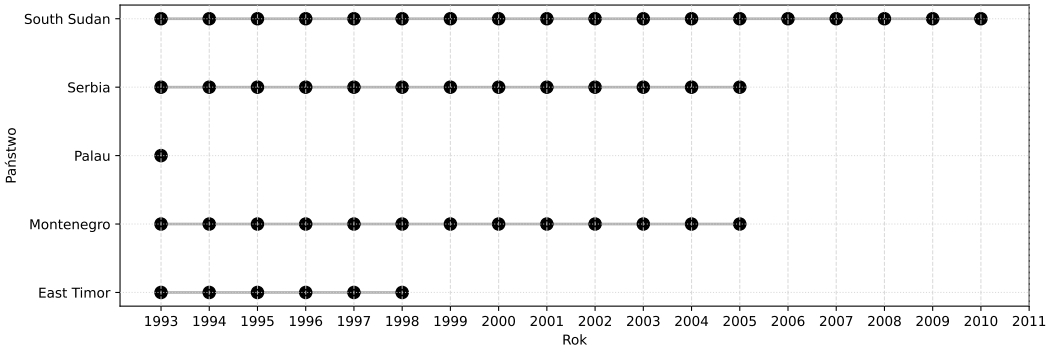

Rysunek 2: *Rozkład braków danych w szeregach czasowych wskaźnika wolności dla wybranych krajów*

Luki, oznaczone na rysunku kropkami, mają charakter systematyczny i wynikają z różnego czasu powstania tych państw. Sudan Południowy wykazuje braki danych do 2010 roku, Serbia oraz Czarnogóra do 2005 roku, Timor Wschodni do 1998 roku, natomiast Palau tylko w 1993 roku.

Szczegółowa analiza kompletności zmiennych objaśniających została przeprowadzona niezależnie dla każdego ze scenariuszy SSP, co pozwoliło na identyfikację specyficznych luk informacyjnych. Analiza objęła lata 1993–2100, a jej wyniki zestawiono na Rysunku 3.

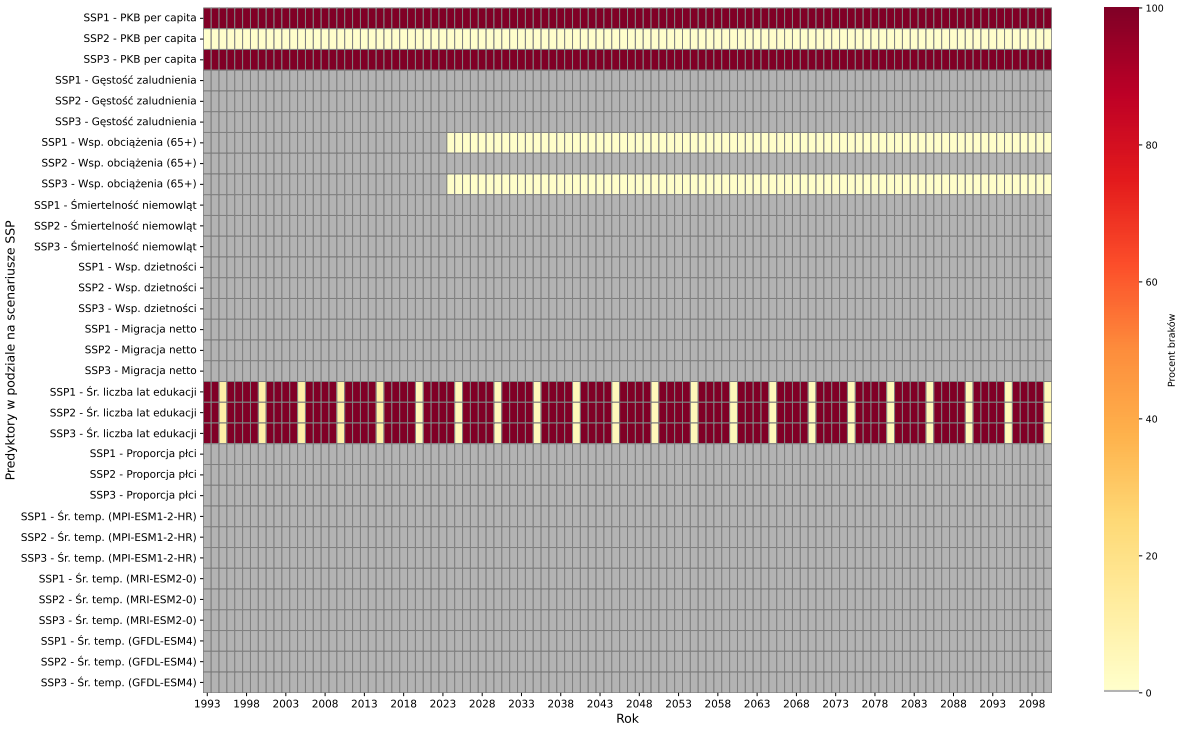

Rysunek 3: *Mapa ciepła braków danych dla zmiennych objaśniających w podziale na SSP (1993–2100)*

- **Wskaźnik obciążenia demograficznego (65+)**
  Całkowita liczba braków wynosi 154, co stanowi zaledwie ok. 0.74% wszystkich obserwacji tego parametru. Luki występują tylko w scenariuszach SSP1 oraz SSP3 w horyzoncie 2024–2100 i dotyczą dwóch państw: Palau oraz Mikronezji. W scenariuszu SSP2 wskaźnik ten jest w pełni kompletny.
- **PKB per capita**
  W scenariuszu SSP2 odnotowano 108 brakujących obserwacji (ok. 0.52%), które wynikają z braku danych dla Liechtensteinu w całym badanym okresie. W scenariuszach SSP1 oraz SSP3 zmienna ta wykazuje całkowity brak danych.
- **Średnia liczba lat edukacji**
  Zgodnie z metodyką gromadzenia danych przez organizację, wskaźnik ten raportowany jest w interwałach pięcioletnich. Powoduje to, że ok. 81% obserwacji w ujęciu rocznym jest pustych. Jednak po ograniczeniu analizy wyłącznie do lat raportowych, liczba braków spada do 286 (6.73% obserwacji). Całkowity brak danych odnotowano dla 10 państw (Saint Kitts i Nevis, Monako, Andora, Liechtenstein, Tuvalu, Nauru, Palau, Wyspy Marshalla, San Marino, Dominika), natomiast dla 11 kolejnych (Antigua i Barbuda, Dżibuti, Grenada, Papua-Nowa Gwinea, Seszele, Uzbekistan, Erytrea, Libia, Brunei, Barbados, Mauretania) brakuje danych historycznych.

Warto zaznaczyć, że dla pozostałych predyktorów nie odnotowano żadnych braków danych. Mając na uwadze cel pracy, którym jest budowa modelu zdolnego do generowania prognoz dla wszystkich państw członkowskich ONZ, wszystkie zidentyfikowane luki zostaną uzupełnione.

Obsługa braków danych

Przeanalizowane luki zostały uzupełnione przy użyciu metod dostosowanych do charakteru danej zmiennej. Celem podjętych działań było uzyskanie kompletnego panelu danych, co stanowi warunek konieczny dla poprawnego procesu uczenia modeli maszynowych i zapewnienia wysokiej wiarygodności przeprowadzanych symulacji w horyzoncie 2100 roku.

Wskaźnik wolności (*Freedom in the World*)

Luki w danych dla wybranych państw wynikają z ich ewolucji geopolitycznej w badanym okresie (1993–2024). W celu zachowania ciągłości szeregów czasowych przyjęto następujące zasady uzupełniania danych:

- **Serbia oraz Czarnogóra**
  W latach 1992–2003 oba kraje tworzyły Federalną Republikę Jugosławii, a następnie (2003–2006) funkcjonowały jako wspólnota państwowa Serbii i Czarnogóry [25]. Brakujące wartości dla obu podmiotów sprzed 2006 roku zostaną uzupełnione danymi przypisanymi ich historycznym poprzednikom, które figurują w zestawieniu zbiorczym.

- **Timor Wschodni**
  Mimo to, że państwo uzyskało pełną suwerenność w 2002 roku, w zestawieniu zbiorczym występuje jako niepodległy podmiot od 1999 roku (referendum niepodległościowe). W latach 1993–1998 organizacja Freedom House klasyfikowała ten obszar jako terytorium sporne pod administracją Indonezji. Brakujące wartości zostały pozyskane drogą kwerendy oryginalnych raportów rocznych i ręcznie przypisane do bazy danych [26].

- **Palau**
  Kraj uzyskał niepodległość w 1994 roku, a wcześniej figurował w raportach Freedom House jako terytorium powiernicze pod administracją USA. Dane za rok 1993 zostały uzupełnione na podstawie archiwalnego raportu z tamtego okresu [26].

- **Sudan Południowy**
  Państwo to powstało w 2011 roku wskutek secesji od Sudanu. Przed tą datą terytorium dzisiejszego Sudanu Południowego nie było uregulowane, stąd brak jakichkolwiek danych. Przyjęto założenie metodologiczne, że luki w danych za lata 1993–2010 zostaną uzupełnione wskaźnikami Sudanu sprzed podziału. Metoda ta pozwala najlepiej odzwierciedlić ogólne warunki polityczno-społeczne panujące na tym obszarze przed uzyskaniem niepodległości.

Wskaźnik obciążenia demograficznego (65+)

Braki danych dla tego wskaźnika dotyczyły dwóch państw (Palau oraz Mikronezji) i ograniczały się do części predykcyjnej w scenariuszach SSP1 oraz SSP3. W celu ich uzupełnienia zastosowano autorską adaptację metody imputacji ilorazowej, wykorzystując pełne szeregi czasowe dla scenariusza SSP2 oraz dane agregowane dla regionów geograficznych. Przyjęto założenie, że relacje pomiędzy wartościami wskaźnika w poszczególnych scenariuszach dla danego kraju są zbliżone do relacji obserwowanych w regionie referencyjnym o najwyższym stopniu historycznej korelacji. Zależność sformalizowano poniższym wzorem (1):

$$X_{k,SSPi}(t) = X_{k,SSP2}(t) \cdot \frac{X_{R,SSPi}(t)}{X_{R,SSP2}(t)} \tag{1}$$

Znaczenie symboli i parametrów wykorzystanych w powyższym równaniu jest następujące:

- $\boldsymbol{X_{k,SSPi}(t)}$ → estymowana wartość wskaźnika dla kraju k w scenariuszu $SSPi$ (gdzie $i \in \{1, 3\}$) w roku t,
- $\boldsymbol{X_{k,SSP2}(t)}$ → znana wartość wskaźnika dla kraju k w scenariuszu bazowym SSP2,
- $\boldsymbol{X_{R,SSPi}(t)}$ → wartość wskaźnika dla regionu referencyjnego R w scenariuszu $SSPi$,
- $\boldsymbol{X_{R,SSP2}(t)}$ → wartość wskaźnika dla regionu referencyjnego R w scenariuszu bazowym SSP2.

W celu wyboru optymalnego regionu odniesienia przeprowadzono analizę korelacji Pearsona pomiędzy historycznymi szeregami danych krajowych i regionalnych. Zastosowano tożsamy zestaw dla obu państw, co podyktowane jest ich przynależnością do tych samych struktur geograficznych i geopolitycznych oraz podobieństwem w zakresie uwarunkowań społeczno-ekonomicznych. Rozważono trzy kategorie odniesienia.

- **Mikronezja** (region)
  Obejmuje niewielkie państwa wyspiarskie zachodniego Pacyfiku, charakteryzujące się podobną strukturą demograficzną i gospodarczą.
- **Oceania** (z wyłączeniem Australii i Nowej Zelandii)
  Szerszy, zróżnicowany region wysp Pacyfiku.
- **SIDS Pacific** (Small Island Developing States)
  Małe rozwijające się państwa wyspiarskie, borykające się z podobnymi barierami strukturalnymi.

W obu przypadkach najwyższą i istotną statystycznie korelację wykazały dane dla regionu Mikronezja (Tabela 1). W związku z tym, do estymacji brakujących predykcji dla Palau i Mikronezji użyto wartości dla tego regionu.

Tabela 1: *Współczynniki korelacji Pearsona między krajowymi a regionalnymi szeregami danych historycznych dla wskaźnika obciążenia demograficznego*

Region odniesienia	**Palau**		**Mikronezja**	
	corr	*p-value*	*corr*	*p-value*
Mikronezja (region)	**0.6195**	< 0.001	**0.7531**	< 0.001
Oceania	0.1681	0.1523	0.2465	0.0342
SIDS Pacific	0.2441	0.0361	0.3065	0.0079

PKB per capita

Zidentyfikowano dwa kluczowe problemy dotyczące tego wskaźnika: całkowity brak danych dla Liechtensteinu oraz dostępność projekcji wyłącznie dla scenariusza SSP2.

Ze względu na brak danych źródłowych PKB per capita (PPP, 2021 USD) dla Liechtensteinu w dostępnych bazach międzynarodowych, zastosowano metodę imputacji opartą na danych Szwajcarii, pełniącej funkcję kraju referencyjnego (*proxy*). Wykorzystano nominalne wartości PKB per capita, co było możliwe dzięki ścisłym powiązaniom gospodarczym obu państw. Tworzą one jednolity obszar celny oraz unię walutową, co implikuje zbliżony poziom cen towarów i usług. W warunkach tak głębokiej integracji różnice w nominalnym PKB per capita odzwierciedlają faktyczne różnice w sile nabywczej mieszkańców, co pozwala na wykorzystanie danych nominalnych jako wiarygodnego mnożnika dla wartości PPP. Metodologia imputacji obejmowała dwa etapy.

- **Dane historyczne (1990–2023)**
  Na podstawie danych Banku Światowego [27] obliczono roczny stosunek nominalnego PKB per capita Liechtensteinu do Szwajcarii. Uzyskany współczynnik przemnożono przez szwajcarskie dane PKB per capita (PPP, 2021 USD).

- **Prognoza (2024–2100)**
  Dla okresu prognostycznego przyjęto stały mnożnik, obliczony jako średnia arytmetyczna relacji nominalnego PKB per capita obu krajów z ostatniej dostępnej dekady (lata 2014–2023). Mnożnik ten nałożono na projekcje PKB per capita (PPP, 2021 USD) dla Szwajcarii przewidziane w scenariuszu SSP2.

Proces wyznaczania brakujących danych dla scenariuszy SSP1 oraz SSP3 w horyzoncie czasowym 2024–2100 został oparty na metodzie relatywnych współczynników różnic względem scenariusza SSP2. Podstawę do obliczeń stanowiły dane z modelu IIASA GDP 2023 [28]. Model ten opiera się na teorii wyrównywania poziomów rozwoju gospodarczego, zakładającej, że w długim terminie gospodarki rozwijające się dążą do osiągnięcia poziomu PKB państw wysoko rozwiniętych. Tempo tego procesu jest determinowane przez czynniki specyficzne dla każdego ze scenariuszy SSP. Dane źródłowe udostępnione w interwałach pięcioletnich są wyrażone w USD według parytetu siły nabywczej z roku bazowego 2017. Należy zaznaczyć, że inny rok bazowy danych IIASA nie wpływa negatywnie na wyniki, ponieważ z tego zbioru wyprowadzane są jedynie współczynniki proporcji między scenariuszami, które następnie aplikowane są do właściwej bazy danych.

Ze względu na to, że dane źródłowe są dostępne w krokach pięcioletnich, brakujące lata zostały uzupełnione przy użyciu metody PCHIP (*Piecewise Cubic Hermite Interpolating Polynomial*). W przeciwieństwie do standardowej interpolacji liniowej PCHIP generuje gładkie przebiegi, co lepiej oddaje ewolucyjny charakter wzrostu gospodarczego. Kluczową przewagą jest jednak zachowanie monotoniczności danych. Klasyczne interpolatory wyższego rzędu mają tendencję do tworzenia sztucznych wahań krzywej, co mogłoby skutkować powstaniem nieuzasadnionych analitycznie lokalnych maksimów lub minimów między punktami węzłowymi. PCHIP eliminuje to ryzyko, nie zmieniając kierunku trendu wyznaczonego przez dane bazowe i nie tworząc fałszywych wybrzuszeń.

W analizowanym zbiorze danych zidentyfikowano 13 państw, dla których model źródłowy nie udostępnia projekcji. Braki te zostały uzupełnione poprzez zastosowanie podejścia opartego na państwach referencyjnych (*proxy*), dobieranych na podstawie kryteriów podobieństwa strukturalnego, bliskości geograficznej oraz silnych powiązań makroekonomicznych. Metoda ta opiera się na założeniu, że gospodarki funkcjonujące w zbliżonych uwarunkowaniach regionalnych i cechujące się podobnym modelem rozwojowym wykazują zbliżoną reakcję na globalne uwarunkowania zdefiniowane w scenariuszach SSP.

W przypadkach, w których danej jednostce przypisano więcej niż jedno państwo referencyjne, docelowe współczynniki różnic wyznaczono jako średnią arytmetyczną. Takie podejście pozwoliło na skuteczniejszą estymację typowej dla danego regionu dynamiki zmian oraz ograniczyło ryzyko błędu wynikającego ze specyficznych odchyleń lub fluktuacji pojedynczych gospodarek referencyjnych, co znacząco zwiększa wiarygodność analityczną uzyskanych wyników. Współczynniki różnic wyznaczono na podstawie następujących przypisań:

- **Andora → Francja, Hiszpania**
  Andora jest silnie powiązana gospodarczo z Francją i Hiszpanią poprzez unię celną oraz dominującą rolę sektora usług, w szczególności turystyki, zależnej od napływu odwiedzających z obu krajów sąsiednich.
- **Monako → Francja**
  Monako funkcjonuje jako gospodarcza i walutowa enklawa Francji, podlegająca tym samym regulacjom rynkowym, co sprawia, że dynamika PKB Francji dobrze odzwierciedla zmiany scenariuszowe w Monako.
- **San Marino → Włochy**
  San Marino jest w pełni zintegrowane z włoskim rynkiem pracy i handlu, a jego rozwój gospodarczy pozostaje ściśle uzależniony od koniunktury we Włoszech.
- **Liechtenstein → Szwajcaria**
  Liechtenstein pozostaje w ścisłej unii celnej i walutowej ze Szwajcarią, co skutkuje bardzo podobną ścieżką rozwoju gospodarczego obu państw.
- **Nauru → Vanuatu, Fidżi**
  Vanuatu i Fidżi pełnią funkcję proxy dla Nauru jako przedstawiciele małych gospodarek wyspiarskich Pacyfiku o zbliżonych ograniczeniach strukturalnych i wysokiej wrażliwości na czynniki zewnętrzne.
- **Tuvalu, Wyspy Marshalla, Palau → Fidżi, Vanuatu, Samoa, Wyspy Salomona**
  Średnia dynamika wzrostu tych państw odzwierciedla typową dla regionu Pacyfiku podatność na szoki zewnętrzne oraz skutki zmian klimatycznych, przy jednocześnie lepszej dostępności danych.
- **Dominika, Saint Kitts i Nevis → Saint Lucia, Antigua i Barbuda, Barbados**
  Kraje te współdzielą bardzo podobną strukturę gospodarczą, opartą głównie na sektorze usług i turystyce karaibskiej, co uzasadnia zastosowanie wspólnych państw proxy.
- **Syria → Irak, Jemen**
  Syria, Irak i Jemen należą do grupy państw dotkniętych chroniczną niestabilnością, w których dynamika PKB jest w dużej mierze determinowana przez czynniki pozarynkowe i kryzysowe.
- **Wenezuela → Boliwia, Nikaragua**
  Wenezuela, Boliwia i Nikaragua charakteryzują się zbliżonym profilem ryzyk instytucjonalnych oraz wysoką zmiennością polityczno-ekonomiczną.

- **Afganistan → Sudan, Jemen**
  Afganistan, Sudan i Jemen cechują się najniższym poziomem stabilności, a ich ścieżki wzrostu w scenariuszach SSP są w dużym stopniu determinowane przez bezpieczeństwo oraz wydolność struktur administracyjnych.

Ostatnim etapem było matematyczne wyprowadzenie wartości dla scenariuszy SSP1 i SSP3. Dla każdego kraju i każdego roku t z przedziału 2024–2100 obliczono bezwymiarowe współczynniki relacji na podstawie danych IIASA [28] zgodnie z równaniem (2).

$$k_{SSP1}(t) = \frac{GDP_{SSP1}(t)}{GDP_{SSP2}(t)}, \quad k_{SSP3}(t) = \frac{GDP_{SSP3}(t)}{GDP_{SSP2}(t)} \tag{2}$$

Następnie wyznaczone mnożniki, wyliczone bezpośrednio lub poprzez kraje *proxy*, zostały przyłożone do wartości scenariusza SSP2 w docelowej bazie danych. Takie podejście pozwoliło na wiarygodne odwzorowanie różnic między scenariuszami przy zachowaniu ciągłości danych.

Średnia liczba lat edukacji

Pierwszym zidentyfikowanym problemem w analizowanym zbiorze były braki danych historycznych dla zmiennej w latach 1990–2015 dla 11 państw. W celu ograniczenia luk pozyskano dane dla tego wskaźnika z bazy ONZ, *Human Development Reports* [29]. Szeregi czasowe obejmowały zróżnicowane zakresy lat, zestawione w Tabeli 2.

Tabela 2: *Zakresy dostępnych danych historycznych dla zmiennej edukacyjnej pozyskanych z ONZ*

Państwo	**Rok początkowy**	**Rok końcowy**
Antigua i Barbuda	2000	2023
Barbados	1990	2023
Brunei	1990	2023
Dżibuti	1995	2023
Erytrea	2005	2023
Grenada	2002	2023
Libia	1990	2023
Mauretania	1990	2023
Papua–Nowa Gwinea	1990	2023
Seszele	2000	2023

Dla pięciu państw (Barbados, Brunei, Libia, Mauretania, Papua–Nowa Gwinea) pozyskano wymagane dane historyczne, co umożliwiło ich bezpośrednie wykorzystanie bez dalszej imputacji. Dla pozostałych krajów zakres braków ograniczył się do lat, które nie zostały znalezione w bazie ONZ. Braki te dotyczyły następujących obserwacji:

- **Grenada** → 1990, 1995, 2000
- **Dżibuti** → 1990
- **Seszele** → 1990, 1995
- **Antigua i Barbuda** → 1990, 1995
- **Erytrea** → 1990, 1995, 2000
- **Uzbekistan** → 1990, 1995

W celu uzupełnienia tych luk zastosowano metodę krajów referencyjnych (*proxy*), opartą na przynależności geograficznej. Każdemu państwu przypisano odpowiedni region, a następnie dla ostatniego dostępnego roku wspólnego obliczono współczynnik relacji pomiędzy wartością krajową a grupą. Nałożono go na szeregi regionalne, co pozwoliło na estymację braków. Dane obszarów referencyjnych pochodzą z tego samego źródła co główny zbiór dla wskaźnika edukacyjnego, a przyporządkowanie krajów przedstawiono poniżej:

- **Azja Centralna** → Uzbekistan,
- **Afryka Wschodnia** → Erytrea, Seszele, Dżibuti,
- **Karaiby** → Grenada, Antigua i Barbuda.

Kolejnym problemem były całkowite braki danych dla 10 państw. W tych przypadkach również pozyskano dane historyczne z bazy ONZ i zastosowano analogiczną metodę regionalną. Współczynnik relacji obliczono na podstawie ostatniego roku historycznego dla prognoz oraz najwcześniejszego dostępnego roku dla danych retrospektywnych. W przypadku Monako całkowity brak danych historycznych uniemożliwił obliczenie współczynnika, dlatego przyjęto wartości grupy dla całego okresu. Dostępność danych regionalnych dla wszystkich scenariuszy SSP pozwoliła na wyznaczenie osobnych współczynników dla każdego z nich, co zapewniło spójność wypełnienia luk w każdym wariancie. Zakresy danych historycznych dla tych państw przedstawiono w Tabeli 3, a przyporządkowanie państw do regionów było następujące:

- **Mikronezja** → Nauru, Tuvalu, Palau, Wyspy Marshalla,
- **Karaiby** → Saint Kitts i Nevis, Dominika,
- **Europa Zachodnia** → Andora, Monako, Liechtenstein,
- **Europa Południowa** → San Marino.

Tabela 3: *Zakresy danych historycznych pozyskanych dla krajów z bazy UNDP*

Państwo	**Rok początkowy**	**Rok końcowy**
Andora	2000	2023
Dominika	2000	2023
Liechtenstein	1990	2023
Wyspy Marshalla	2011	2023
Nauru	2000	2023
Palau	2000	2023
San Marino	1990	2023
Saint Kitts i Nevis	2005	2023
Tuvalu	1990	2023

Ostatecznie wszystkie luki w szeregach czasowych zostały zinterpolowane metodą PCHIP, opisaną w części dotyczącej wskaźnika PKB per capita, uzyskując pełne dane roczne w okresie 1993–2100.

Transformacja i agregacja danych wejściowych

Przed przystąpieniem do eksploracyjnej analizy danych, dane wejściowe poddano transformacjom mającym na celu ich unifikację oraz poprawę jakości statystycznej.

Wskaźnik wolności składa się z dwóch komponentów, ocenianych w skali od 1 do 7, przy czym wartość 1 oznacza najwyższy poziom wolności, a 7 – najniższy. Taka konstrukcja skali jest nieintuicyjna w kontekście korelacji ze wskaźnikami ekonomicznymi, gdzie zazwyczaj wyższe wartości reprezentują korzystniejsze zjawiska. W celu ujednolicenia kierunku interpretacji zmiennych dokonano inwersji skali obu komponentów. W wyniku tej transformacji wartość 7 odpowiada maksymalnemu poziomowi wolności, a 1 minimalnemu. Następnie, aby zredukować wymiarowość danych przy jednoczesnym zachowaniu informacji o ogólnym stanie przestrzegania praw człowieka w danym państwie, oba komponenty zintegrowano w jeden zbiorczy wskaźnik wolności, wyznaczony jako średnia arytmetyczna.

Drugim istotnym etapem przygotowania danych była agregacja zmiennej dotyczącej średniej rocznej temperatury powietrza. W zebranych danych znajdowały się trzy prognozy, generowane przez niezależne modele klimatyczne. W celu zminimalizowania błędów systematycznych, specyficznych dla pojedynczych modeli, oraz ograniczenia niepewności predykcji klimatycznej uśredniono wartości prognoz z trzech modeli.

Ostatnim etapem przygotowania danych była integracja wszystkich zmiennych w trzy zbiory danych odpowiadające scenariuszom SSP1, SSP2 oraz SSP3. Każdy z tych zbiorów zawierał kompletne szeregi czasowe w okresie 1993–2100, gotowe do dalszej analizy.

Eksploracyjna analiza danych

Analiza globalnego trendu wskaźnika wolności

Analiza dynamiki zmian zmiennej objaśnianej w ujęciu historycznym stanowi fundament dla zrozumienia procesów kształtujących skalę naruszeń praw człowieka na świecie. W tym celu zbadano ewolucję globalnego wskaźnika wolności w ciągu ostatnich trzech dekad. Rysunek 4 prezentuje średnią światową tego wskaźnika w latach 1993–2024, co pozwala na identyfikację kluczowych trendów oraz punktów zwrotnych w globalnej polityce w zakresie praw człowieka.

Wstępna obserwacja danych wskazuje na relatywną stabilność wskaźnika, który w badanym okresie poruszał się w wąskim kanale wahań, oscylując wokół wartości 4.5. Mimo braku gwałtownych skoków o dużej amplitudzie, na wykresie można wyraźnie wyodrębnić trzy istotne etapy rozwoju sytuacji geopolitycznej. Pierwszy z nich, trwający od początku lat 90. do około 2005 roku, charakteryzuje się tendencją wzrostową. To odzwierciedlenie fali demokratyzacji po zakończeniu zimnej wojny, transformacji ustrojowej krajów Europy Środkowo-Wschodniej oraz rozszerzenia Unii Europejskiej, co w sposób systemowy podniosło globalne standardy praworządności.

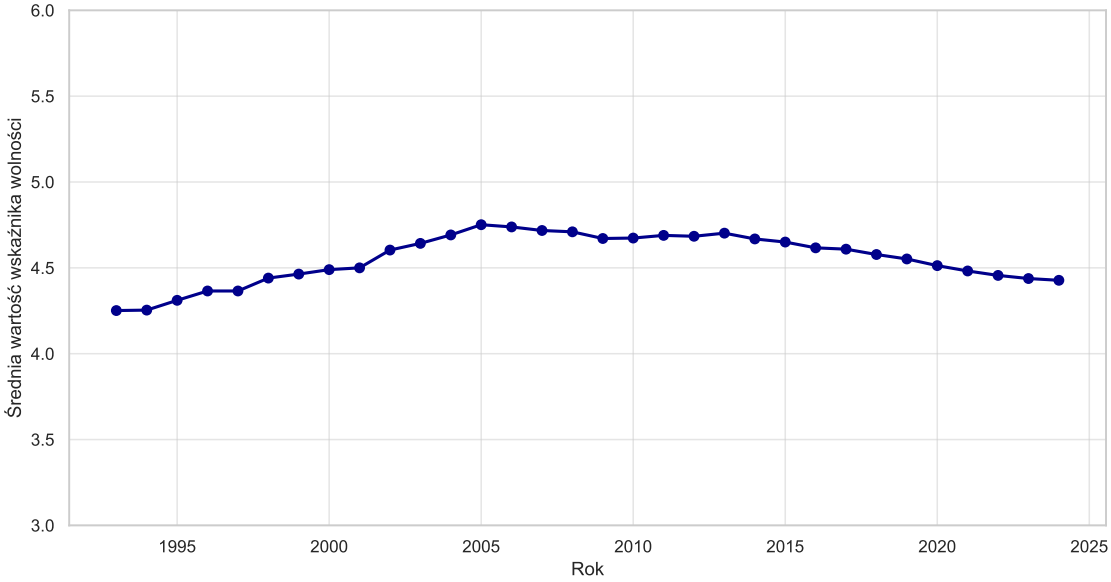

Rysunek 4: *Globalny trend wskaźnika wolności w latach 1993–2024*

Druga faza, przypadająca na lata 2005–2013, to okres stabilizacji na historycznie wysokim poziomie. Choć w tym czasie dochodziło do wydarzeń dających nadzieję na dalszą liberalizację, takich jak Arabska Wiosna, globalny wzrost został zahamowany. Wpływ na to miały między innymi skutki światowego kryzysu finansowego z 2008 roku, który doprowadził do napięć społecznych i osłabienia zaufania do instytucji demokratycznych w wielu regionach.

Ostatni etap, obserwowany od 2013 roku, wskazuje na niepokojący i konsekwentny trend spadkowy. Wartość wskaźnika w 2024 roku powróciła do poziomów notowanych niemal trzydzieści lat wcześniej. Regres ten jest powiązany z narastającą konsolidacją władzy w państwach autorytarnych oraz występującymi konfliktami zbrojnymi.

Globalny poziom wolności nie podlega jednostajnemu postępowi, lecz wykazuje zmienność i dużą wrażliwość na globalne kryzysy polityczne oraz gospodarcze.

Geograficzne zróżnicowanie wskaźnika wolności w 2024 roku

Po analizie dynamiki czasowej globalnego wskaźnika wolności dokonano weryfikacji jego rozkładu przestrzennego. Pozwala to na zidentyfikowanie regionalnych skupisk oraz państw o charakterystyce odbiegającej od trendów kontynentalnych. Mapa (Rysunek 5) prezentuje stan wskaźnika w 2024 roku, stanowiąc punkt wyjścia dla modelu predykcyjnego.

Wizualizacja danych ukazuje wyraźną polaryzację świata, która wykracza poza tradycyjny podział na bogatą Północ i rozwijające się Południe. Dominującym zjawiskiem jest koncentracja wysokiego poziomu wolności w obszarze transatlantyckim (Ameryka Północna, Europa Zachodnia i Północna) oraz w regionie Australii i Nowej Zelandii. Państwa te konsekwentnie osiągają najwyższe noty, co na mapie zaznaczono intensywnym kolorem zielonym.

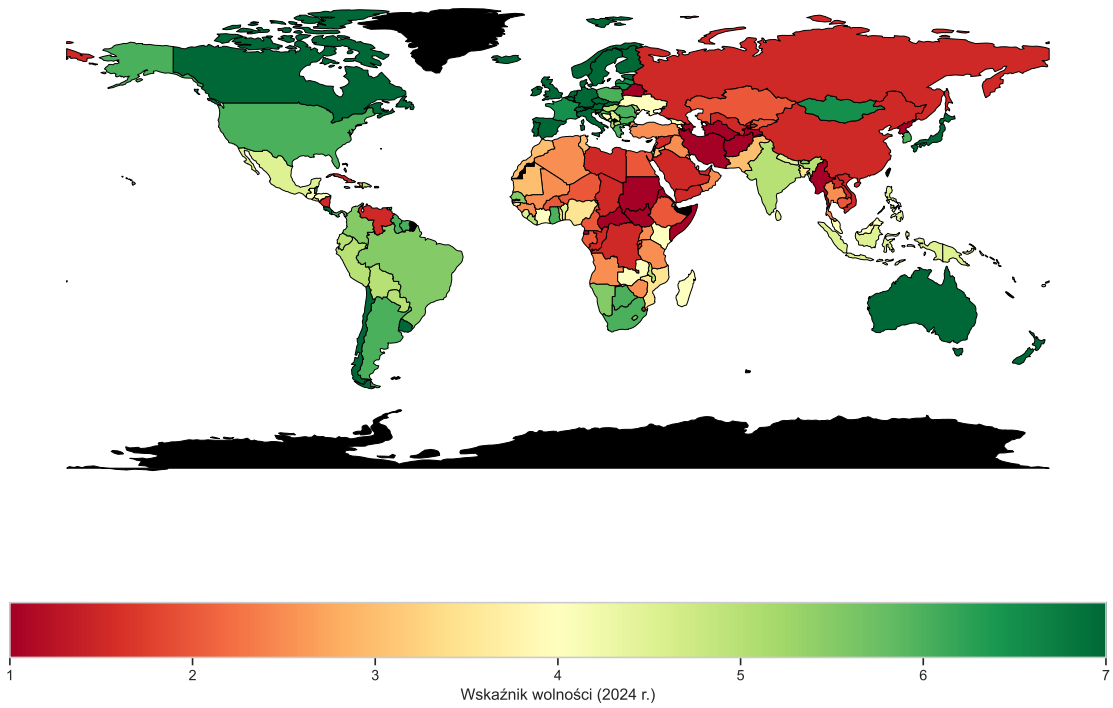

Rysunek 5: *Rozkład geograficzny wskaźnika wolności na świecie w 2024 roku*

Kontrastuje to silnie z blokiem eurazjatyckim, gdzie mocarstwa takie jak Rosja i Chiny, wraz z państwami Azji Centralnej i znaczną częścią Bliskiego Wschodu, tworzą zwarty obszar o niskich standardach wolności obywatelskich, reprezentowany przez odcienie czerwieni.

Szczególnie interesujący z punktu widzenia analizy danych jest obszar tzw. Globalnego Południa, który charakteryzuje się największą wariancją wyników. Ameryka Południowa prezentuje relatywnie stabilny, umiarkowanie wysoki poziom wolności, z wyraźnymi wyjątkami takimi jak Wenezuela, która statystycznie odstaje od swoich sąsiadów. Z kolei Afryka jawi się jako kontynent o największym zróżnicowaniu wewnętrznym. Regiony południowe (np. RPA, Botswana) utrzymują standardy demokratyczne, a Afryka Północna i Środkowa zdominowana jest przez systemy autorytarne. W Europie natomiast dostrzegalny jest gradient wschodni, wraz z przemieszczaniem się w stronę granic Federacji Rosyjskiej, wskaźnik wolności ulega systematycznemu obniżeniu, co obrazuje bezpośredni wpływ stabilności regionalnej na kondycję praw człowieka.

Świat w 2024 roku jest głęboko podzielony na bloki ideologiczno-polityczne. Taka struktura danych sugeruje, że przyszłe prognozy do roku 2100 nie mogą opierać się wyłącznie na uśrednionych trendach globalnych, lecz powinny uwzględniać specyfikę regionalną. Wyraźne granice między strefami o wysokim i niskim poziomie wolności wskazują na istnienie barier systemowych, których przełamanie w nadchodzących dekadach będzie wymagało gwałtownych zmian o charakterze zewnętrznym, co stanowi istotne wyzwanie dla stabilności prognoz długoterminowych.

Analiza trendów zmiennych objaśniających w scenariuszach rozwoju

Rysunek 6 przedstawia średnie globalne przebiegi historyczne oraz projekcje w trzech scenariuszach Wspólnych Ścieżek Społeczno-Ekonomicznych wszystkich zmiennych objaśniających.

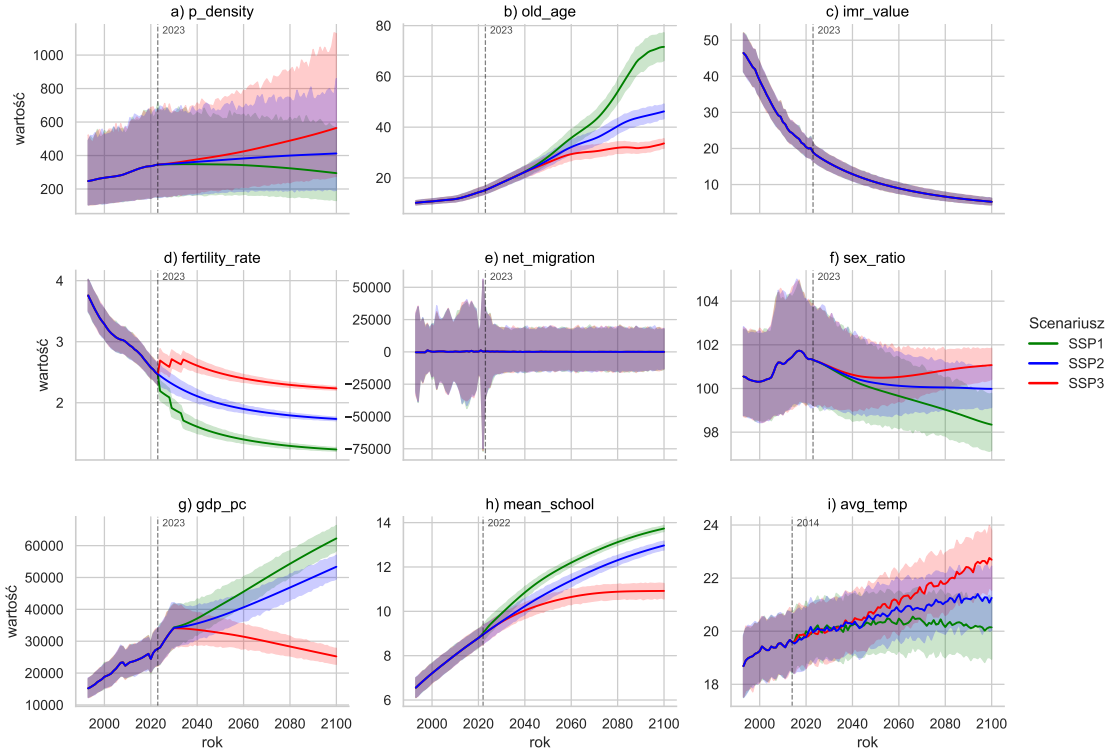

Rysunek 6: *Dynamika zmiennych objaśniających w podziale na scenariusze SSP1, SSP2 i SSP3*

We wszystkich analizowanych scenariuszach obserwowany jest trend spadkowy współczynnika dzietności (*fertility_rate*), jednak tempo tego zjawiska istotnie się różni. W scenariuszu SSP1 następuje szybka stabilizacja na poziomie znacznie poniżej zastępowalności pokoleń, podczas gdy w wariancie SSP3 dzietność utrzymuje się na relatywnie wysokim poziomie, co w konsekwencji prowadzi do dalszego wzrostu gęstości zaludnienia (*p_density*).

W przypadku śmiertelności niemowląt (*imr_value*) również obserwowany jest trend spadkowy, a saldo migracji (*net_migration*) w projekcji osiąga ustabilizowany przedział ufności. Występowanie tylko jednego scenariusza dla tych zmiennych wynika z przyjętej metodologii projekcji przez ONZ.

Wymiar społeczno-gospodarczy charakteryzuje się silną współzależnością pomiędzy poziomem edukacji (*mean_school*) a PKB per capita (*gdp_pc*). W scenariuszach SSP1 i SSP2 dynamiczny wzrost kapitału ludzkiego przekłada się na wzrost dobrobytu, podczas gdy w scenariuszu SSP3 stagnacja edukacyjna powiązana jest ze spowolnieniem rozwoju gospodarczego. Procesom tym towarzyszy narastające obciążenie osobami starszymi (*old_age*). Zjawisko to jest szczególnie wyraźne w scenariuszu SSP1, gdzie wysoka średnia długość życia przy jednoczesnej niskiej dzietności prowadzi do najszybszego starzenia się społeczeństw.

Z perspektywy środowiskowej średnia temperatura (*avg_temp*) rośnie we wszystkich wariantach, przy czym w scenariuszu SSP3 wzrost ten nie wykazuje oznak wyhamowania nawet pod koniec XXI wieku, w przeciwieństwie do SSP1, gdzie widoczne są efekty skutecznej polityki klimatycznej.

Analiza rozkładu wskaźników

W niniejszej sekcji przeprowadzono szczegółową analizę statystyczną zbioru danych historycznych, który posłuży do nauki modelu. W przypadku zmiennych objaśniających, dla których dane historyczne kończą się przed 2024 rokiem, zdecydowano się na wykorzystanie wartości pochodzących ze scenariusza SSP2. Takie podejście pozwoliło na zachowanie ciągłości danych dla zmiennej celu, wskaźnika wolności, bez konieczności redukcji zbioru o najnowsze obserwacje z ostatniego okresu. Przyjęto założenie metodologiczne, że w krótkim horyzoncie czasowym scenariusz SSP2 wystarczająco precyzyjnie oddaje rzeczywiste trendy.

Analiza wskaźnika wolności

Wskaźnik cechuje się umiarkowanym poziomem globalnym (średnia 4.55, mediana 5.0), przy czym różnica między tymi miarami wskazuje na asymetrię lewostronną rozkładu, wynikającą z relatywnie większej liczby państw o niższym poziomie wolności. Histogram (Rysunek 7) potwierdza spłaszczony charakter rozkładu (niską kurtozę) oraz równomierne rozproszenie wartości w niemal całej skali, co znajduje odzwierciedlenie także w wykresie pudełkowym, na którym nie występują obserwacje odstające, zgodnie z ograniczeniem skali do przedziału $[1, 7]$. Szeroki zakres międzykwartylowy i pełne pokrycie skali świadczą o wysokiej wariancji zmiennej celu, co z perspektywy uczenia maszynowego stanowi korzystną własność, zapewniając modelowi zróżnicowane wzorce i ograniczając ryzyko nadmiernego dopasowania.

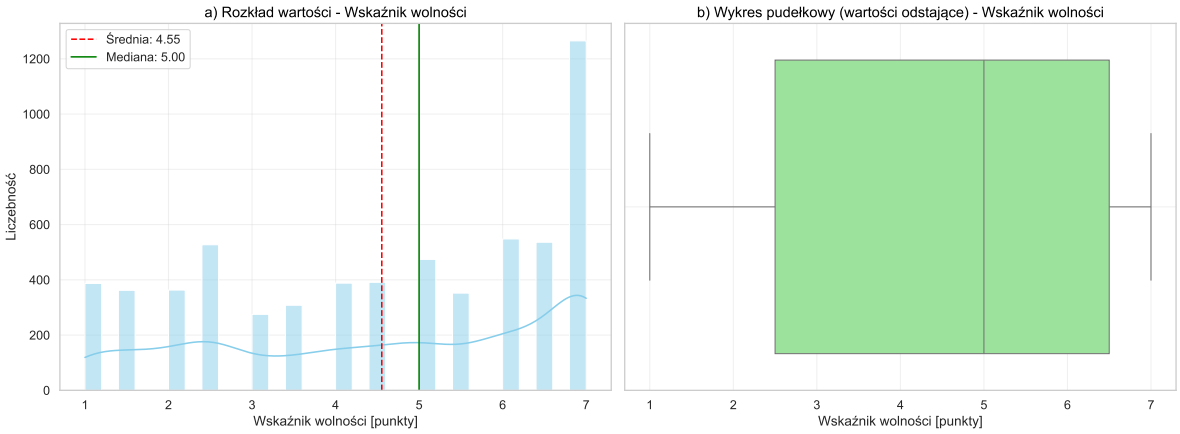

Rysunek 7: *Histogram rozkładu oraz wykres pudełkowy wskaźnika wolności w latach 1993–2024*

Analiza gęstości zaludnienia

Wskaźnik charakteryzuje się skrajną asymetrią i bardzo dużą rozpiętością wartości (Rysunek 8), średnia (295.41 os/km^2) niemal czterokrotnie przewyższa medianę (76.80 os/km^2), co wskazuje, że typowe państwo jest słabo zaludnione, a średnia globalna jest silnie zawyżana przez nieliczne, ekstremalnie zagęszczone terytoria. Potwierdzają to bardzo wysoka skośność prawostronna (12.27) oraz ekstremalna kurtoza (158.44), świadczące o ciężkim prawym ogonie rozkładu. Wykres pudełkowy ujawnia liczne wartości odstające, sięgające ponad 26.000 os/km^2, co czyni zmienną problematyczną z perspektywy uczenia maszynowego, gdyż może destabilizować proces uczenia.

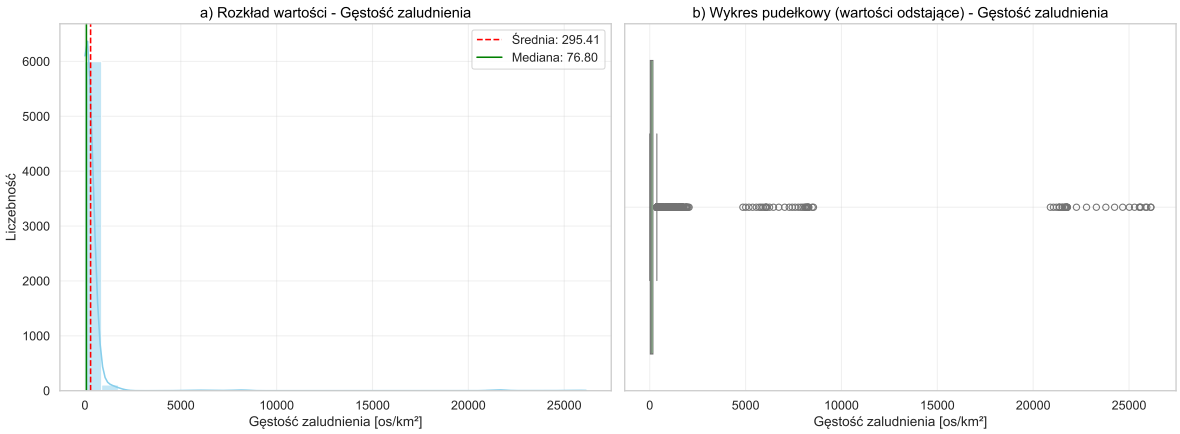

Rysunek 8: *Histogram rozkładu oraz wykres pudełkowy wskaźnika gęstości zaludnienia w latach 1993–2024*

Analiza obciążenia demograficznego osobami starszymi

Wskaźnik obciążenia demograficznego (Rysunek 9) wykazuje wyraźną prawostronną asymetrię (średnia 12.09, mediana 8.35, skośność 1.59), co odzwierciedla dominację krajów o relatywnie młodej strukturze wiekowej, typowej dla państw rozwijających się. Podwyższona kurtoza (3.86) wskazuje na zwiększoną koncentrację obserwacji w ogonach rozkładu, a analiza wykresu pudełkowego oraz wartość maksymalna (74.79) potwierdzają obecność istotnych wartości odstających. Są to państwa wysokorozwinięte w fazie zaawansowanego starzenia się populacji.

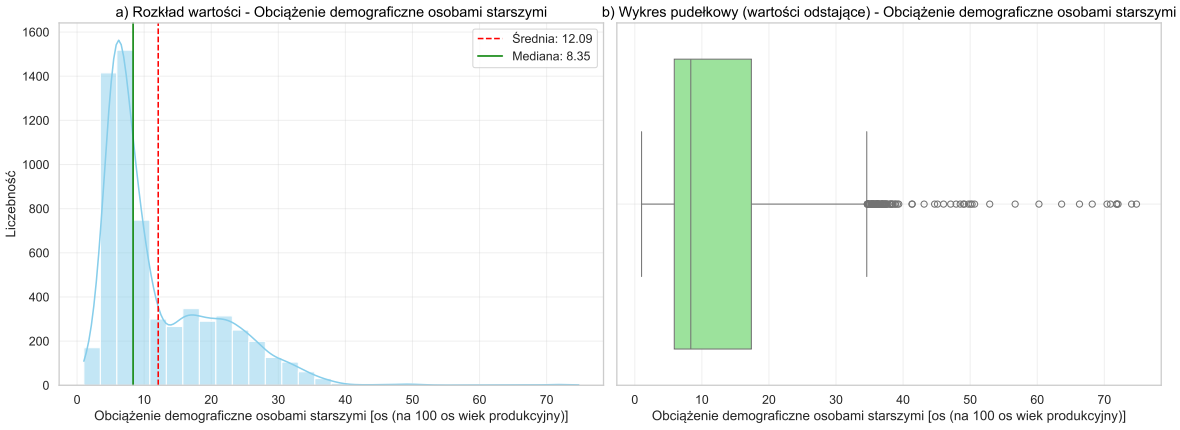

Rysunek 9: *Histogram rozkładu oraz wykres pudełkowy wskaźnika obciążenia demograficznego osobami starszymi w latach 1993–2024*

Analiza śmiertelności niemowląt

Wskaźnik wykazuje wyraźną asymetrię prawostronną (skośność 1.47), co potwierdza znaczna różnica między średnią a medianą (18.56). Struktura rozkładu (Rysunek 10) wskazuje na dominację państw o niskiej śmiertelności, przy jednoczesnym występowaniu wąskiej grupy krajów o skrajnie wysokich wartościach. Wykres pudełkowy ujawnia liczne wartości odstające powyżej górnego kwartyla, odpowiadające regionom o poważnych deficytach systemów ochrony zdrowia, a dodatnia kurtoza (2.08) potwierdza koncentrację obserwacji przy niskich poziomach zmiennej przy jednoczesnym ciężkim prawym ogonie rozkładu.

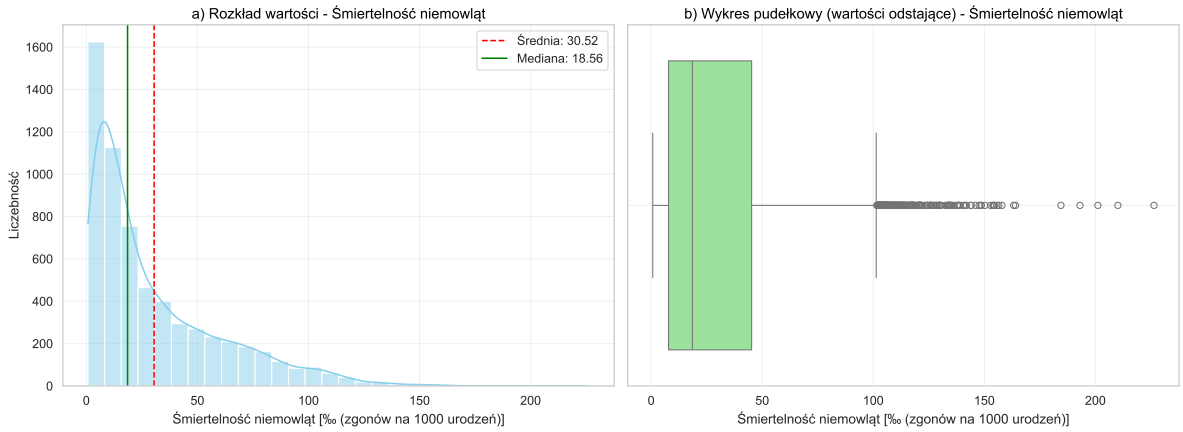

Rysunek 10: *Histogram rozkładu oraz wykres pudełkowy wskaźnika śmiertelności niemowląt w latach 1993–2024*

Analiza współczynnika dzietności

Rozkład współczynnika (Rysunek 11) wykazuje asymetrię prawostronną (średnia 3.02, mediana 2.51, skośność 0.92). Wskazuje to na globalną transformację demograficzną, większość państw spadła poniżej poziomu zastępowalności pokoleń, a jedynie nieliczne kraje o bardzo wysokiej dzietności zawyżają średnią globalną. Obecność wartości odstających powyżej 6.0 oraz maksimum na poziomie 8.05 identyfikuje państwa w fazie eksplozji demograficznej, natomiast ujemna, bliska zeru kurtoza (-0.15) potwierdza spłaszczony rozkład, odzwierciedlający wyraźny podział świata na regiony starzejące się i regiony o wysokim potencjale wzrostu.

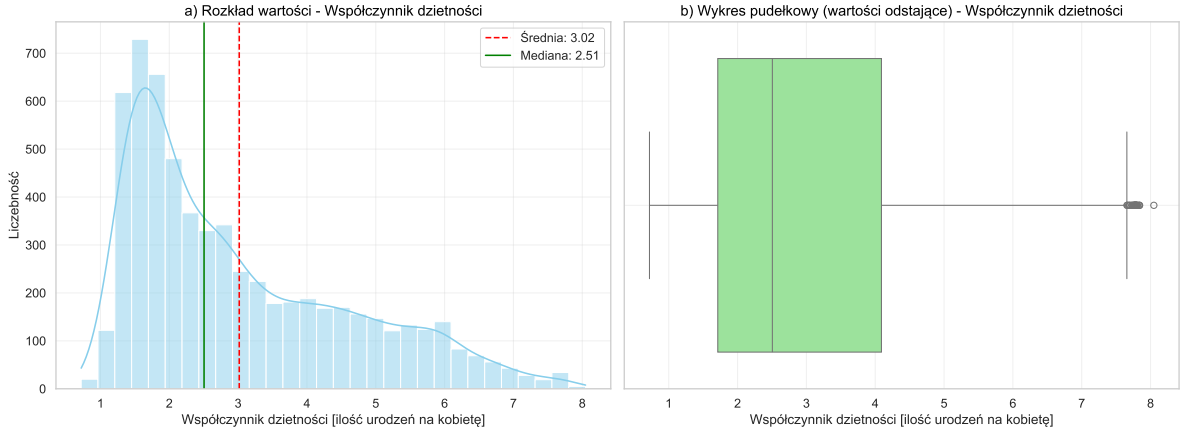

Rysunek 11: *Histogram rozkładu oraz wykres pudełkowy współczynnika dzietności w latach 1993–2024*

Analiza salda migracji netto

Wskaźnik, zgodnie ze swoją globalną naturą, charakteryzuje się średnią bliską zeru (ok. 240.92 osoby), przy jednoczesnej skrajnie wysokiej zmienności, czego dowodzi odchylenie standardowe przekraczające 215 tys. Rozkład (Rysunek 12) jest silnie lewoskośny (skośność -3.11), co wskazuje, że epizody masowej emigracji, najczęściej związane z konfliktami i prześladowaniami, mają większą skalę i gwałtowność niż procesy masowej imigracji. Bardzo wysoka kurtoza (105.44) oraz wąski zakres międzykwartylowy potwierdzają silną koncentrację większości obserwacji wokół zera przy jednoczesnym występowaniu ekstremalnych wartości odstających, sięgających milionów osób, które odzwierciedlają największe kryzysy migracyjne analizowanego okresu.

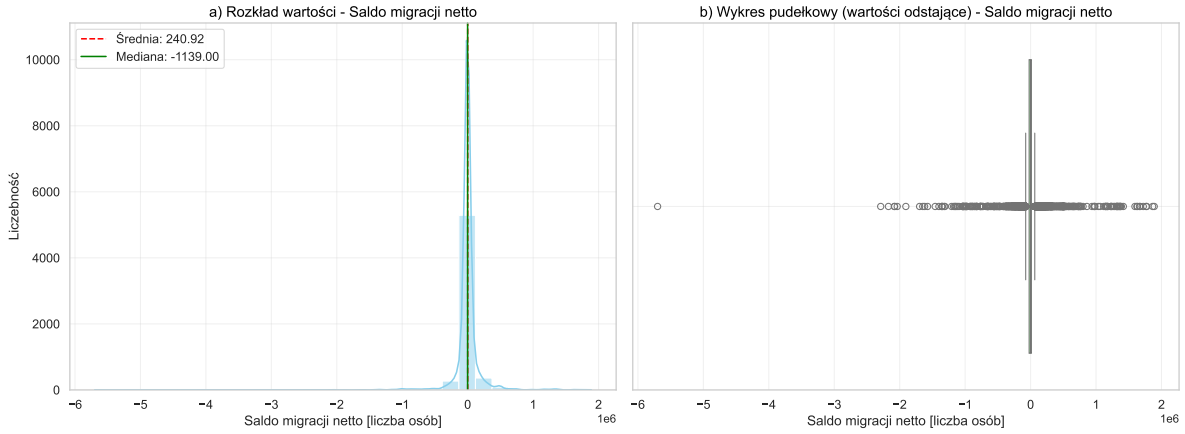

Rysunek 12: *Histogram rozkładu oraz wykres pudełkowy salda migracji netto w latach 1993–2024*

Analiza stosunku płci

Rozkład wskaźnika (Rysunek 13) charakteryzuje się silną koncentracją wartości wokół biologicznej równowagi, przy czym mediana (98.54) wskazuje na niewielką nadwyżkę kobiet w typowym państwie, a średnia (100.96) jest wyraźnie zawyżana przez skrajną asymetrię prawostronną (skośność 6.80). Nadzwyczaj wysoka kurtoza (60.16) nadaje rozkładowi silnie smukły charakter, co oznacza, że większość obserwacji skupia się w wąskim przedziale, natomiast prawy ogon zawiera ekstremalne wartości odstające, sięgające 319.85.

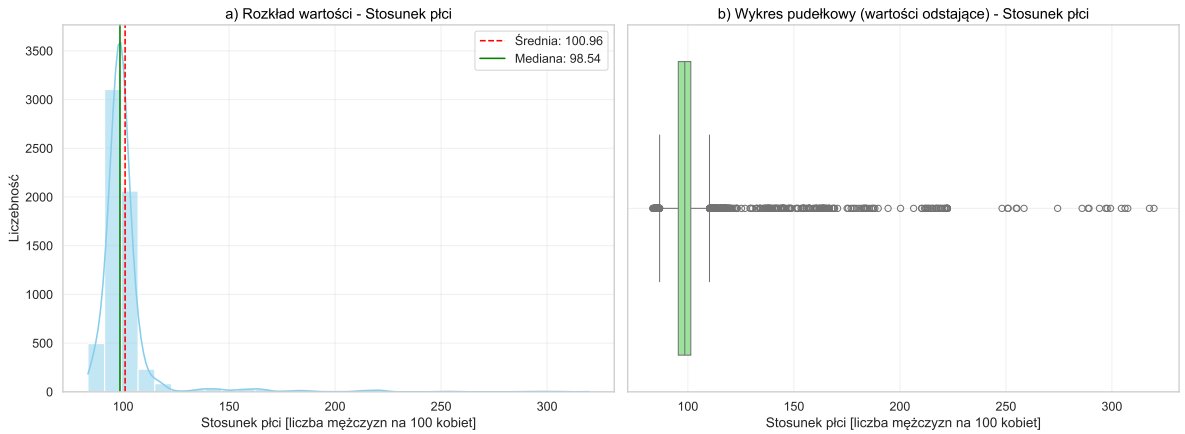

Rysunek 13: *Histogram rozkładu oraz wykres pudełkowy wskaźnika stosunku płci w latach 1993–2024*

Analiza PKB per capita

Rozkład wskaźnika (Rysunek 14) cechuje się skrajnym zróżnicowaniem, bardzo wysokie odchylenie standardowe (ok. 32 tys. USD) oraz wyraźna dysproporcja między średnią (22 006 USD) a medianą (11 791 USD) wskazują na głębokie nierówności dochodowe w skali globalnej. Silna asymetria prawostronna (skośność 5.29) oznacza, że większość państw należy do grupy krajów o niskim i średnim dochodzie, natomiast średnia globalna jest zawyżana przez najbogatsze gospodarki. Wykres pudełkowy i bardzo wysoka kurtoza (47.40) ujawniają silną koncentrację obserwacji w dolnym zakresie oraz długi prawy ogon z ekstremami przekraczającymi 467 000 USD, co odzwierciedla strukturalne rozwarstwienie ekonomiczne świata.

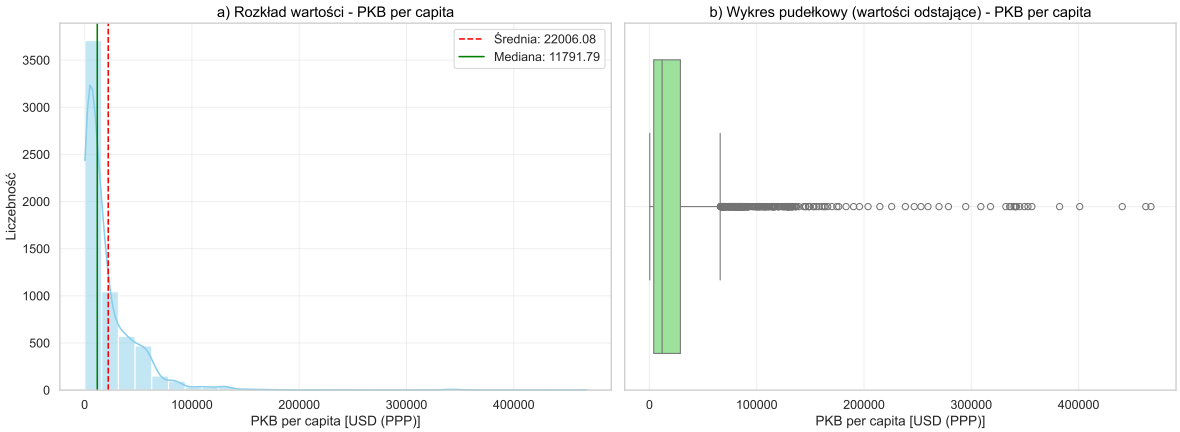

Rysunek 14: *Histogram rozkładu oraz wykres pudełkowy wskaźnika PKB per capita (1993–2024)*

Analiza średniej liczby lat edukacji

Wskaźnik (Rysunek 15) charakteryzuje się zrównoważonym, ciągłym rozkładem z łagodną asymetrią lewostronną (mediana 8.47; średnia 7.88; skośność -0.43), co odzwierciedla globalne upowszechnienie edukacji i fakt, że połowa państw przekroczyła poziom ośmiu lat kształcenia dorosłych. Ujemna kurtoza (-0.87) oraz szeroki rozstęp międzykwartylowy potwierdzają spłaszczony charakter rozkładu i płynne zróżnicowanie wartości w całej skali, bez występowania obserwacji odstających, co wskazuje na brak gwałtownych dysproporcji statystycznych między państwami.

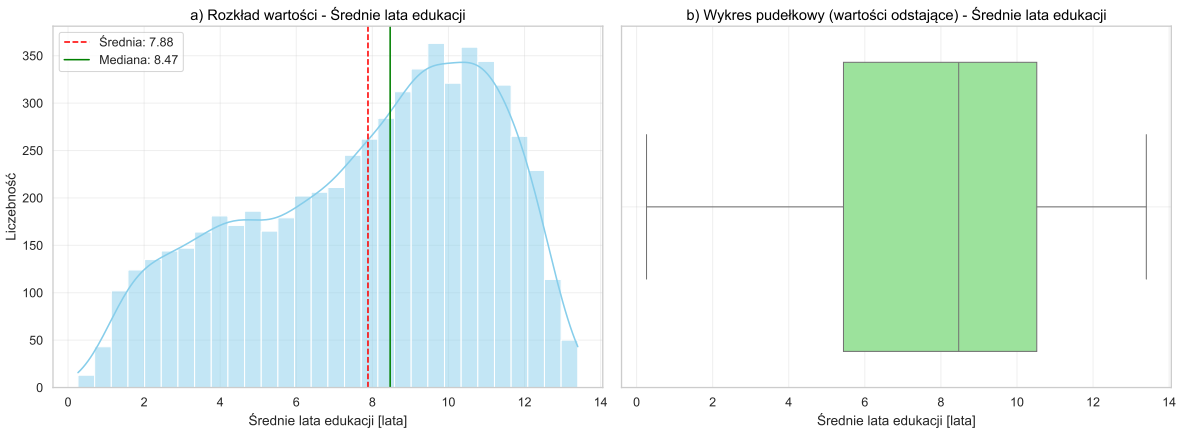

Rysunek 15: *Histogram rozkładu oraz wykres pudełkowy średniej liczby lat edukacji (1993–2024)*

Analiza średniej temperatury

Rozkład wskaźnika (Rysunek 16) wykazuje asymetrię lewostronną (skośność -0.81), przy czym mediana (23.21 °C) wyraźnie przewyższa średnią (19.46 °C), co wskazuje na dominację państw położonych w strefach ciepłych. Ujemna kurtoza (-0.56) potwierdza spłaszczony charakter rozkładu oraz szerokie, równomierne zróżnicowanie geograficzne – od wartości minimalnych rzędu -5.30 °C po maksima około 30.07 °C. Wykres pudełkowy ujawnia szeroki rozstęp międzykwartylowy, przesunięcie rozkładu ku wyższym temperaturom oraz brak obserwacji odstających, co sugeruje ciągłość przejść między strefami klimatycznymi.

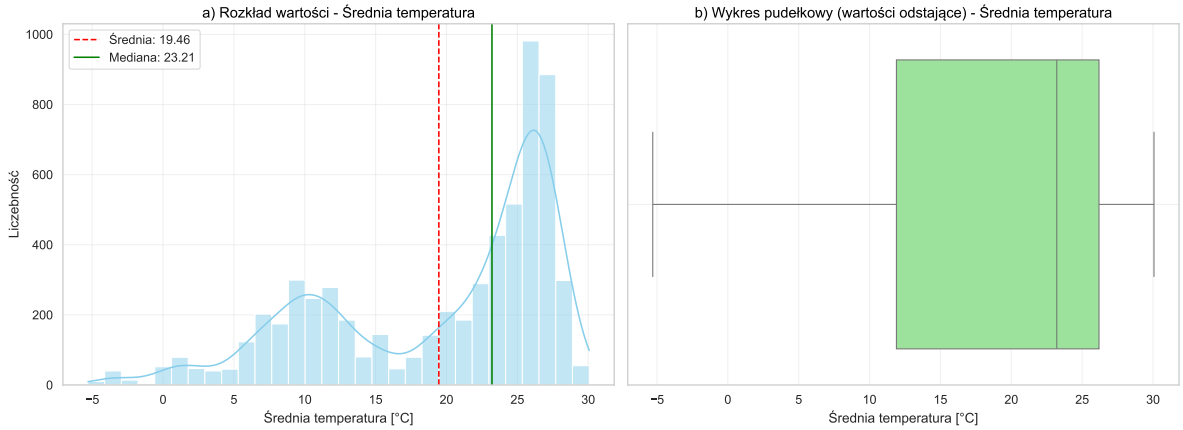

Rysunek 16: *Histogram rozkładu oraz wykres pudełkowy średniej temperatury (1993–2024)*

Analiza korelacji zmiennych objaśniających ze wskaźnikiem wolności

Zrozumienie współzależności między badanymi wskaźnikami a zmienną celu jest niezbędnym etapem przygotowania danych do procesu modelowania. Pozwala to na zweryfikowanie istotności statystycznej predyktorów oraz identyfikację siły i kierunku ich oddziaływania na poziom wolności. Ze względu na brak rozkładu normalnego u większości analizowanych zmiennych oraz obecność licznych wartości odstających, do analizy zależności zastosowano współczynnik korelacji rang Spearmana. Metoda ta umożliwia wykrywanie zależności monotonicznych, co czyni ją odporniejszą na nieliniowy charakter relacji między zmiennymi. Rysunek 17 prezentuje macierz korelacji oraz ranking czynników wpływających na wskaźnik wolności.

Szczegółowa analiza wyników pozwala na wyodrębnienie grupy stymulantów, których wzrost jest skorelowany z wyższym poziomem wolności i przestrzegania praw człowieka. Najsilniejszym pozytywnym predyktorem okazał się współczynnik obciążenia demograficznego osobami starszymi (0.60), co wiąże się z faktem, że zaawansowana faza transformacji demograficznej jest domeną państw wysokorozwiniętych o ugruntowanych systemach demokratycznych. Istotną rolę odgrywa również kapitał ludzki wyrażony przez średnią liczbę lat nauki (0.53) oraz poziom zamożności mierzony PKB per capita (0.51). Wyższa edukacja społeczeństwa sprzyja budowaniu świadomości obywatelskiej, a stabilność ekonomiczna umożliwia formowanie się klasy średniej, stanowiącej fundament demokratycznego porządku.

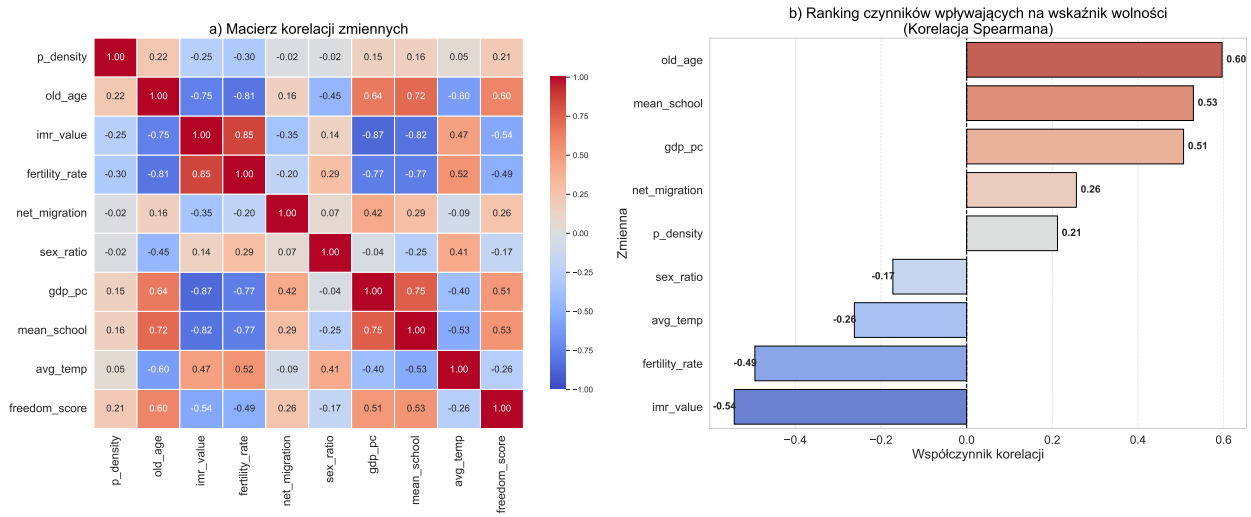

Rysunek 17: *Macierz korelacji zmiennych oraz ranking siły wpływu na wskaźnik wolności (korelacja Spearmana)*

Ponadto zauważalna jest dodatnia korelacja z saldem migracji (0.26) oraz gęstością zaludnienia (0.21), co sugeruje, że państwa wolne są częściej celem migracji, a wysoki stopień urbanizacji może ułatwiać samoorganizację społeczeństwa obywatelskiego.

Po przeciwnej stronie spektrum znajdują się destymulanty, wykazujące ujemną korelację ze wskaźnikiem wolności. Najsilniejszym negatywnym czynnikiem jest śmiertelność niemowląt (-0.54), która stanowi bezpośredni indykator ubóstwa i niewydolności struktur państwowych w zakresie ochrony życia i zdrowia. Podobny trend dotyczy wysokiego współczynnika dzietności (-0.49), często współwystępującego z niską pozycją społeczną kobiet i brakiem reform modernizacyjnych. Umiarkowane zależności ujemne odnotowano także w przypadku średniej temperatury (-0.26) oraz współczynnika maskulinizacji (-0.17). Te korelacje mogą odzwierciedlać wyzwania środowiskowe i kulturowe, które utrudniają rozwój instytucji demokratycznych w niektórych regionach świata.

Zestaw zmiennych objaśniających charakteryzuje się wysoką wartością informacyjną dla modelu predykcyjnego. Silne powiązania wskaźnika wolności z czynnikami demograficznymi, edukacyjnymi i ekonomicznymi potwierdzają zasadność podejścia wielowymiarowego.

Analiza nieliniowości i charakteru zależności

Wykorzystanie wykresów rozrzutu wzbogaconych o krzywe trendu (Rysunek 18) pozwoliło na identyfikację złożonych wzorców, które determinują dynamikę praw człowieka.

Analiza danych umożliwia wyróżnienie kilku charakterystycznych typów relacji funkcyjnych między predyktorami a wskaźnikiem wolności. Zmienne o charakterze logarytmicznym, takie jak PKB per capita (*gdp_pc*) oraz obciążenie demograficzne osobami starszymi (*old_age*), wykazują silny wzrost poziomu wolności na wczesnych etapach rozwoju, który po przekroczeniu określonych progów ulega wyraźnemu spowolnieniu, wskazując na efekt nasycenia instytucjonalnego.

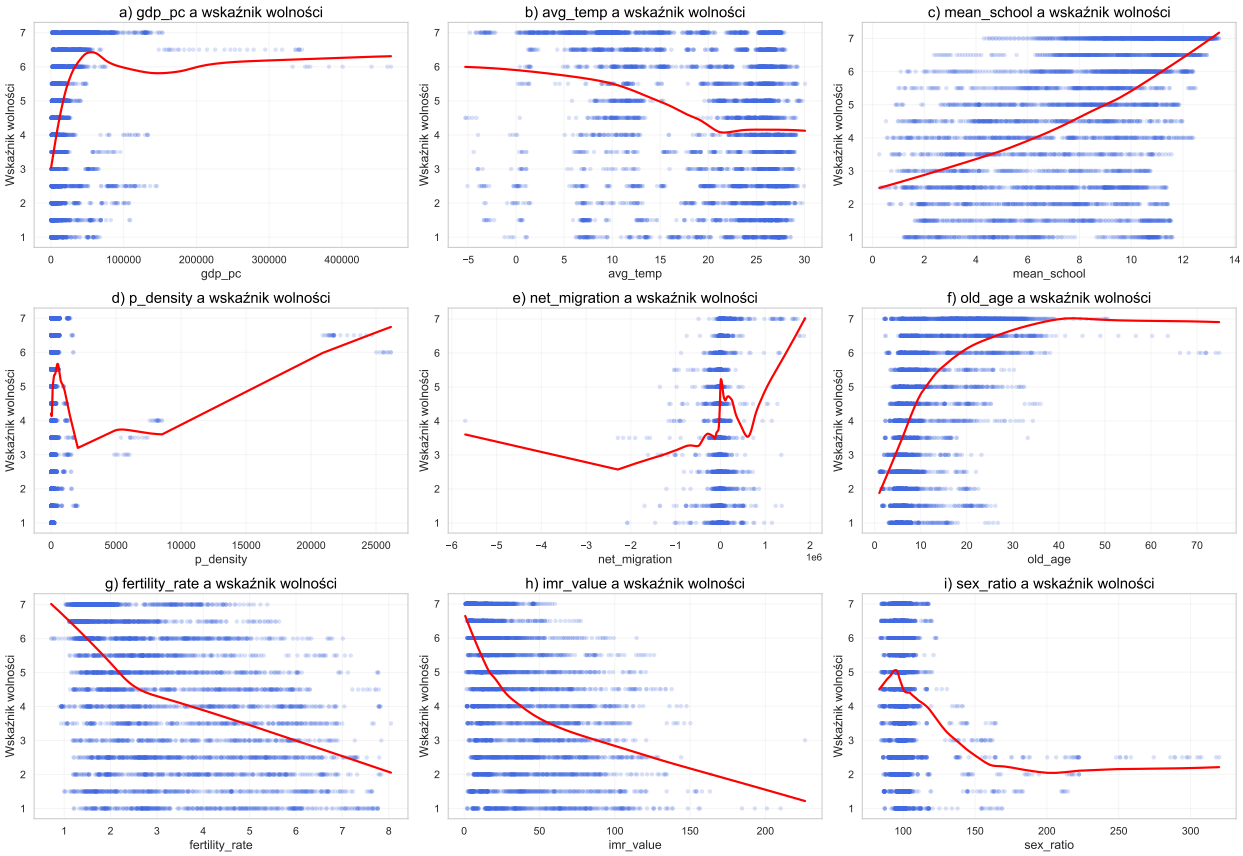

Rysunek 18: *Wizualizacja zależności nieliniowych: zmienne objaśniające względem wskaźnika wolności*

Odmienny przebieg mają zależności wykładnicze malejące, charakterystyczne dla śmiertelności niemowląt (*imr_value*) oraz współczynnika dzietności (*fertility_rate*). Już niewielki wzrost tych zmiennych wiąże się z gwałtownym spadkiem poziomu wolności, przy czym dalsze pogarszanie parametrów skutkuje wolniejszą dynamiką regresu. Zmienne progowe, takie jak stosunek płci (*sex_ratio*) oraz średnia temperatura (*avg_temp*), zachowują względną stabilność jedynie w określonych zakresach, natomiast przekroczenie wartości krytycznych prowadzi do skokowego załamania trendu, co może odzwierciedlać wpływ czynników klimatycznych i strukturalnych na rozwój instytucjonalny.

Predyktory o niemonotonicznej strukturze to saldo migracji (*net_migration*), wykazujące relację zbliżoną do kształtu litery U, oraz gęstość zaludnienia (*p_density*), dla której obserwowane są lokalne maksima zarówno w regionach słabo zaludnionych, jak i w wysoko rozwiniętych państwach-miastach. Na tym tle średnia liczba lat edukacji (*mean_school*) wyróżnia się niemal liniową zależnością, gdzie każdy dodatkowy rok kształcenia przekłada się proporcjonalnie na wzrost wskaźnika wolności, czyniąc ją najbardziej stabilnym i przewidywalnym predyktorem w analizowanym zbiorze.

Inżynieria cech

Agregacja Geopolityczna

Kolumna zawierająca informacje o kraju ma wysoką kardynalność (193 unikalne wartości). Bezpośrednie kodowanie każdego państwa prowadziłoby do powstania macierzy o bardzo dużej liczbie kolumn, co zwiększa ryzyko przeuczenia oraz utrudnia interpretację modelu.

Zastosowano agregację krajów do 11 makroregionów geopolitycznych według standardu **MESSAGE** (*Model for Energy Supply Strategy Alternatives and their General Environmental Impact*). Wybór ten jest podyktowany zdolnością tego schematu do separacji bloków o odmiennej historii politycznej i strukturze gospodarczej. W przeciwieństwie do prostych podziałów wyodrębnia on regiony kluczowe dla analizy demokracji, przykładowo:

- **FSU (Former Soviet Union)** → Kraje postradzieckie, co pozwala uchwycić specyfikę transformacji ustrojowej w tym obszarze.
- **CPA (Centrally Planned Asia)** → Region obejmujący m.in. Chiny, oddzielony od demokratycznych Indii (SAS).
- **MEA vs AFR** → Wyraźne rozróżnienie krajów arabskich (Bliski Wschód i Afryka Płn.) od Afryki Subsaharyjskiej.
- **WEU vs EEU** → Rozróżnienie ugruntowanych demokracji Europy Zachodniej od młodszych demokracji Europy Wschodniej.

Zmienne zakodowano binarnie (*One-Hot Encoding*), z podziałem na następujące regiony:

NAM → Ameryka Północna
LAM → Ameryka Łacińska i Karaiby
WEU → Europa Zachodnia
EEU → Europa Wschodnia
FSU → Były Związek Radziecki
MEA → Bliski Wschód i Afryka Północna
AFR → Afryka Subsaharyjska
CPA → Azja Centralnie Planowana
SAS → Azja Południowa (Indie)
PAS → Pozostała część Azji
PAO → Pacyfik OECD

Transformacja zmiennych nieliniowych

W oparciu o wyniki analizy opracowano strategię preprocesingu mającą na celu linearyzację zmiennych objaśniających. Działanie to jest niezbędne dla zwiększenia efektywności algorytmów uczenia maszynowego, w szczególności modeli z rodziny regresji liniowej, które wykazują wysoką wrażliwość na asymetrię rozkładu oraz obecność wartości odstających. Zmienne podzielono na trzy grupy operacyjne, dobierając metody transformacji adekwatne do zdiagnozowanego kształtu krzywych trendu.

1. Zmienne o charakterystyce logarytmicznej i trendach wykładniczych

Do tej grupy zaliczono predyktory: *gdp_pc*, *old_age* oraz *imr_value* i *fertility_rate*. Podjęto decyzję o zastosowaniu transformacji logarytmicznej $log(1+x)$. Pozwala ona na efektywną linearyzację zależności poprzez rozciągnięcie wartości w dolnych zakresach i kompresję skali dla wartości wysokich, co przywraca stabilną korelację liniową ze zmienną celu.

2. Zmienne o wysokiej asymetrii i długich ogonach

Zmienne *p_density* oraz *sex_ratio* charakteryzują się asymetrią prawostronną i występowaniem ekstremalnych wartości odstających. Zastosowanie transformacji $log(1 + x)$ miało na celu redukcję wpływu obserwacji skrajnych poprzez ich przybliżenie do centrum rozkładu.

3. Zmienne w skali oryginalnej

Zrezygnowano z transformacji matematycznych dla zmiennych *mean_school*, *avg_temp* oraz *net_migration*. Pierwsza z nich wykazuje niemal idealną liniowość, niewymagającą korekty. W przypadku pozostałych relacje mają charakter złożony i niemonotoniczny. Pozostawienie skali oryginalnej pozwala na zachowanie informacji o lokalnych maksimach i minimach, które mogłyby zostać zatarte przez transformacje monotoniczne.

Skuteczność przyjętej strategii zweryfikowano poprzez porównanie współczynnika korelacji liniowej Pearsona (R) przed i po transformacji. Dla wszystkich wytypowanych zmiennych odnotowano wzrost wartości bezwzględnej współczynnika, co świadczy o lepszym dopasowaniu liniowym do wskaźnika wolności. Wyniki tej analizy zestawiono w Tabeli 4.

Zmienna	**R (oryginał)**	**R (po transformacji)**	**Przyrost (Δ)**
gdp_pc	0.3078	0.4739	+0.1661
p_density	0.0649	0.1631	+0.0982
imr_value	-0.4581	-0.5194	+0.0613
old_age	0.5403	0.5772	+0.0368
sex_ratio	-0.1992	-0.2128	+0.0136
fertility_rate	-0.4567	-0.4700	+0.0134

Tabela 4: *Porównanie współczynnika korelacji Pearsona (R) względem wskaźnika wolności przed i po transformacji logarytmicznej*

Najbardziej znaczącą poprawę odnotowano dla PKB per capita, gdzie wzrost korelacji o 0.166 potwierdził logarytmiczny charakter zależności. Wzmocnienie pozostałych predyktorów dodatkowo stabilizuje bazę informacyjną modelu. Zbiór danych z przetransformowanymi cechami został przyjęty jako ostateczny arkusz wejściowy do etapu modelowania predykcyjnego.

Podział danych na zbiór treningowy i testowy

To kluczowy etap w przygotowaniu zbioru do modelowania. Ze względu na specyfikę danych panelowych (obserwacje dla wielu krajów na przestrzeni lat), zastosowanie losowego podziału byłoby metodologicznie niepoprawne, prowadząc do wystąpienia zjawiska wycieku danych. Zastosowano więc punkt odcięcia na osi czasu, co pozwala na zachowanie struktury czasowej.

- **Zbiór treningowy (1993–2017)** → Służy do nauki wzorców historycznych. Obejmuje okres 25 lat.
- **Zbiór testowy (2018–2024)** → Służy do weryfikacji zdolności modelu do prognozowania przyszłości. Obejmuje ostatnie 7 lat.

Takie podejście symuluje rzeczywiste zastosowanie modelu, gdzie na podstawie danych historycznych musimy przewidzieć przyszłe wartości. Zapobiega to zjawisku *data leakage*, w którym model mógłby znać przyszłość podczas procesu uczenia. Uzyskano podział **78.12**% (trening) do **21.88**% (test), który jest zgodny z najlepszymi praktykami.

Profilowanie Krajów

Standardowe podejście do danych panelowych często napotyka problem reprezentacji specyfiki poszczególnych krajów. Zmienne regionalne są zazwyczaj zbyt ogólne, by oddać indywidualną historię polityczno-ekonomiczną państwa. W celu rozwiązania tego problemu zastosowano metodę profilowania krajów z wykorzystaniem redukcji wymiarowości (PCA).

1. **Agregacja historii**
   Dla każdego kraju obliczono statystyki opisowe (średnia oraz odchylenie standardowe) dla wszystkich zmiennych, w tym wartości wskaźnika wolności. Pozwala to scharakteryzować nie tylko poziom rozwoju, ale i jego stabilność na przestrzeni lat (odchylenie).
2. **Zapobieganie wyciekowi danych**
   Kluczowym założeniem metodologicznym jest obliczenie tych statystyk wyłącznie na podstawie zbioru treningowego (lata ≤ 2017).
3. **Redukcja wymiarowości (PCA)**
   Uzyskana macierz statystyk została skompresowana metodą Analizy Głównych Składowych (PCA) do pięciu cech. Reprezentują one syntetyczny opis kondycji państwa w badanym okresie historycznym. PCA jest klasyczną metodą liniowej redukcji wymiarowości, w której oryginalne, skorelowane zmienne zastępowane są mniejszą liczbą nowych, wzajemnie nieskorelowanych zmiennych (głównych składowych). Każda składowa stanowi liniową kombinację cech wejściowych i maksymalizuje wyjaśnianą wariancję danych, co pozwala zachować większość informacji statystycznej przy istotnym ograniczeniu liczby wymiarów oraz redukcji współliniowości i szumu. Wybór tej techniki liniowej jest w pełni uzasadniony wcześniejszą linearyzacją kluczowych zmiennych oraz oparciem analizy na stabilnych statystykach zagregowanych.

Zbiory posiadają od teraz strukturę hybrydową, łączącą dane bieżące (wskaźniki roczne) z tłem historycznym (profile PCA). Skompresowane profile skutecznie oddają specyfikę społeczno-ekonomiczną państw (69.77% zachowanej wariancji w końcowej syntezie).

Charakterystyka profilów państw

Do interpretacji nowo utworzonych zmiennych wykorzystano macierz ładunków PCA (Rysunek 19), za pomocą której scharakteryzowano zależności pomiędzy zmiennymi pierwotnymi a wyodrębnionymi komponentami. Pozwoliło to na identyfikację znaczenia poszczególnych profili państw.

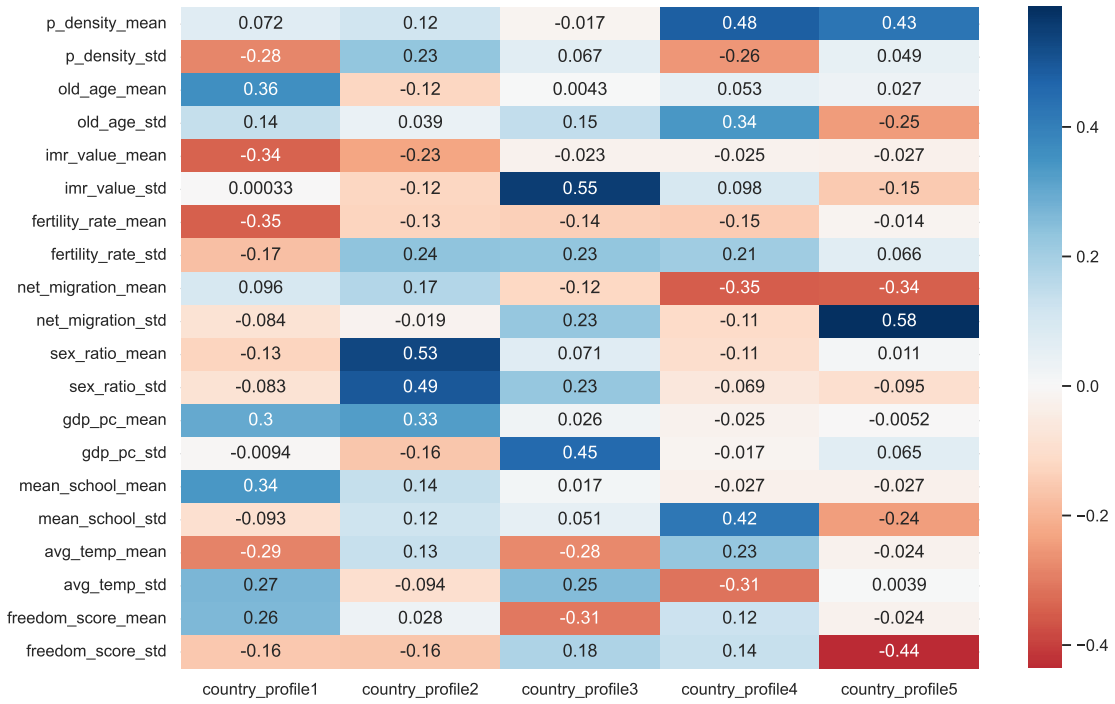

Rysunek 19: *Macierz ładunków dla pięciu składowych profilujących państwa*

country_profile1 (Profil Rozwoju Społeczno-Ekonomicznego)

Składowa silnie dodatnio skorelowana z poziomem edukacji (`mean_school_mean`), PKB per capita (`gdp_pc_mean`) oraz odsetkiem osób starszych (`old_age_mean`), a ujemnie ze śmiertelnością niemowląt (`imr_value_mean`) i dzietnością (`fertility_rate_mean`). Reprezentuje wymiar dojrzałości demograficznej i rozwoju gospodarczego.

country_profile2 (Struktura Płciowa)

Komponent zdominowany przez zmienne opisujące proporcje płci (`sex_ratio`), charakterystyczny dla państw o specyficznej strukturze populacji, często związanej z migracją zarobkową.

country_profile3 (Wskaźnik Niestabilności Gospodarczo-Zdrowotnej)

Składowa oparta głównie na zmienności śmiertelności niemowląt (`imr_value_std`) oraz PKB (`gdp_pc_std`). Wysokie wartości wskazują na kraje doświadczające gwałtownych zmian warunków bytowych, co koreluje ujemnie ze średnim poziomem wolności (`freedom_score_mean`).

country_profile4 (Profil Zagęszczenia i Dynamiki Edukacyjnej)
Profil definiowany przez gęstość zaludnienia (`p_density_mean`) oraz zmienność poziomu edukacji (`mean_school_std`), opisujący państwa o określonej koncentracji ludności i dynamicznych procesach modernizacji systemu kształcenia.

country_profile5 (Dynamika Migracji)
Komponent determinowany przede wszystkim przez zmienność salda migracji, identyfikujący kraje dotknięte niestabilnymi przepływami ludności, co znajduje odzwierciedlenie w ujemnej korelacji ze stabilnością wskaźnika wolności (`freedom_score_std`).

Analiza macierzy ładunków wykazała, że PCA skutecznie wyodrębniło profile państw, różnicując je pod względem rozwoju społeczno-ekonomicznego.

Standaryzacja zmiennych

W tym etapie zmienne numeryczne poddano standaryzacji (*StandardScaler*), tak aby każda cecha miała średnią $\mu = 0$ i odchylenie standardowe $\sigma = 1$. Konieczność tego procesu zależy od charakteru algorytmu, w modelach liniowych i sieciach neuronowych brak standaryzacji zmiennych o różnych rzędach wielkości prowadziłby do dominacji jednych cech nad innymi, niestabilności modelu i wolnej zbieżności. W algorytmach opartych na drzewach przekształcenie danych nie wpływa na ich strukturę ani jakość predykcji. Przeprowadzona standaryzacja pozwoliła przygotować zbiór danych do pracy z modelami wrażliwymi na skalę.

Selekcja Cech

We wcześniejszym etapie analizy zaobserwowano możliwe powiązania między niektórymi zmiennymi objaśniającymi, co sugeruje występowanie zjawiska współliniowości. W celu precyzyjnego zidentyfikowania zmiennych nadmiarowych i uniknięcia niestabilności modeli, szczególnie liniowych, zastosowano wskaźnik **VIF** (*Variance Inflation Factor*). Pozwala on matematycznie ocenić, w jakim stopniu wariancja szacowanego współczynnika regresji jest zawyżona z powodu korelacji z innymi zmiennymi. Pięć najwyższych wartości zaprezentowano w Tabeli 5. Za próg krytyczny przyjęto **VIF = 10**, a zmienne o wyższych wartościach uznano za nadmiarowe i usunięto z analizy.

Cecha	**Wartość VIF**
`country_profile1`	27.0871
`imr_value`	8.2802
`old_age`	8.0332
`country_profile2`	7.9598
`fertility_rate`	7.5074

Tabela 5: *Wstępne 5 najwyższych wartości wskaźnika VIF dla zmiennych objaśniających*

Ponowne obliczenie wskaźników VIF, po usunięciu zmiennej `country_profile1`, potwierdziło skuteczność przyjętej strategii. Wszystkie cechy osiągnęły wartości poniżej przyjętego progu krytycznego (VIF < 10), co prezentuje Tabela 6.

Cecha	**Wartość VIF**
`imr_value`	8.1547
`country_profile2`	7.9522
`fertility_rate`	6.6167
`sex_ratio`	6.5001
`old_age`	6.3109

Tabela 6: *Finalne 5 najwyższych wartości wskaźnika VIF dla zmiennych objaśniających*

Uzyskany zestaw zmiennych objaśniających jest wolny od silnej współliniowości. Macierz jest dobrze uwarunkowana numerycznie, co jest kluczowe dla stabilności estymatorów liniowych. Model będzie opierał się na jawnych wskaźnikach ekonomiczno-społecznych, podczas gdy pozostałe profile (2–5) posłużą do wychwycenia subtelniejszych, nieoczywistych cech specyficznych dla danych państw.

Uczenie maszynowe

Celem niniejszego etapu pracy było wyłonienie modelu predykcyjnego, który w sposób możliwie najdokładniejszy opisuje zależność pomiędzy zestawem zmiennych objaśniających a wskaźnikiem wolności. Przeprowadzono eksperyment porównawczy obejmujący trzy fundamentalnie różne podejścia do modelowania danych: metody liniowe, metody nieliniowe oraz sztuczne sieci neuronowe. Dobór modeli podyktowany był zasadą stopniowego zwiększania złożoności algorytmów.

Modele liniowe

Stanowią punkt odniesienia dla dalszych analiz. Ich celem jest weryfikacja, czy zmienna celu może zostać opisana jako ważona suma zmiennych objaśniających, co wskazywałoby na relatywnie prostą strukturę badanego problemu predykcyjnego.

Regresja liniowa jest klasycznym algorytmem estymacji, szczegółowo opisanym w literaturze ekonometrycznej [30]. Minimalizuje ona sumę kwadratów błędów pomiędzy wartościami rzeczywistymi a predykcjami modelu. Każdej zmiennej objaśniającej przypisywana jest waga, a predykcja stanowi ich liniową kombinację. Model ten zastosowano w konfiguracji domyślnej, bez regularyzacji, jako najprostszy możliwy estymator.

Regresja grzbietowa to rozszerzenie regresji liniowej z regularyzacją L2, która wprowadza karę za wysokie wartości współczynników [31]. W badaniu zastosowano umiarkowaną regularyzację ($alpha = 1.0$), uzasadnioną występowaniem współliniowości wśród zmiennych. Kara L2 stabilizuje estymację wag, ogranicza wariancję modelu i zmniejsza ryzyko przeuczenia, przy zachowaniu wszystkich cech w modelu.

Modele nieliniowe oparte na drzewach decyzyjnych

Ich działanie opiera się na sekwencyjnym podziale przestrzeni cech na regiony jednorodne względem wartości prognozowanej [32]. Każdy podział realizowany jest na podstawie jednej zmiennej oraz progu decyzyjnego, który minimalizuje błąd predykcji w danym węźle drzewa. Zaletą drzew decyzyjnych jest modelowanie złożonych interakcji, gdzie wpływ jednej cechy zależy od wartości innych, co jest trudne do uchwycenia w modelach liniowych.

Random Forest jest algorytmem zespołowym zaproponowanym przez Breimana [33], w którym predykcja powstaje przez uśrednienie wyników wielu niezależnych drzew decyzyjnych, z których każde trenowane jest na losowej próbce danych, co zmniejsza wariancję w porównaniu do pojedynczego drzewa. W eksperymencie zastosowano 100 drzew o maksymalnej głębokości 10, co pozwala uchwycić nieliniowe zależności przy jednoczesnym ograniczeniu ryzyka nadmiernego dopasowania do szumu w danych treningowych.

XGBoost (Extreme Gradient Boosting) to algorytm zespołowy, w którym drzewa decyzyjne budowane są sekwencyjnie, a każdy kolejny model koncentruje się na redukcji błędów poprzednich, stopniowo poprawiając jakość predykcji [34]. W przeciwieństwie do Random Forest, gdzie drzewa uczone są niezależnie, XGBoost minimalizuje globalną funkcję kosztu przy użyciu metody spadku gradientu. W eksperymencie zastosowano umiarkowane tempo uczenia (*learning rate* $= 0.1$) i 100 drzew składowych, co zapewnia stabilną optymalizację oraz skuteczne uchwycenie złożonych, nieliniowych wzorców w danych tabelarycznych.

Sztuczne sieci neuronowe

Sztuczne sieci neuronowe należą do najbardziej elastycznych modeli predykcyjnych. Ich działanie opiera się na propagacji sygnału przez kolejne warstwy neuronów, z których każdy wykonuje transformację liniową, a następnie stosuje nieliniową funkcję aktywacji [35]. Proces uczenia sieci polega na minimalizacji funkcji straty poprzez iteracyjną modyfikację wag połączeń przy użyciu algorytmu propagacji wstecznej błędu.

MLP Simple to wielowarstwowa sieć perceptronowa o prostej strukturze, składająca się z dwóch warstw ukrytych zawierających 64 i 32 neurony [36]. Model pełnił rolę punktu odniesienia w metodach neuronowych, sprawdzając, czy stosunkowo nieskomplikowana architektura potrafi uchwycić zależności w danych. Niewielka liczba warstw i neuronów ogranicza liczbę uczonych parametrów, zmniejszając ryzyko przeuczenia w zbiorach o ograniczonej liczbie obserwacji, a jednocześnie umożliwia modelowanie zależności bardziej złożonych niż w modelach liniowych, przy zachowaniu stabilności procesu uczenia.

MLP Deep to głębsza sieć neuronowa o architekturze lejkowej, składająca się z trzech warstw ukrytych o malejącej liczbie neuronów: 128, 64 i 32, co pozwala stopniowo przekształcać dane wejściowe w coraz bardziej abstrakcyjne reprezentacje i uchwycić złożone wzorce. W sieci zastosowano funkcję aktywacji ReLU, która umożliwia efektywne uczenie głębszych struktur poprzez ograniczenie problemu zanikającego gradientu [37].

Proces optymalizacji realizowany był za pomocą algorytmu Adam [38], który adaptacyjnie dostosowuje krok uczenia dla poszczególnych wag. Dodatkowo wykorzystano mechanizm *early stopping*, przerywający trening w momencie pogorszenia jakości predykcji na zbiorze walidacyjnym, oraz regularyzację L2 o niewielkiej sile (parametr *alpha* równy 0.001), ograniczającą nadmierny wzrost wag sieci.

Analiza i porównanie wyników modelowania

W celu oceny skuteczności opracowanych modeli predykcyjnych przeprowadzono analizę wyników na zbiorze testowym (Tabela 7), wykorzystując trzy standardowe metryki regresji: współczynnik determinacji (R^2), błąd średniokwadratowy (RMSE) oraz średni błąd bezwzględny (MAE). R^2 informuje, jaki procent wariancji zmiennej celu został wyjaśniony przez model, przy czym wartość bliska jeden oznacza niemal idealne dopasowanie. RMSE to średnia wielkość błędu, w której duże odchylenia są karane silniej niż małe, dzięki podniesieniu ich do kwadratu. Pozwala to ocenić stabilność prognoz i wrażliwość modelu na duże błędy. MAE oblicza średnią bezwzględną różnicę między prognozami a wartościami rzeczywistymi, dając intuicyjny obraz typowego błędu w tych samych jednostkach, co zmienna prognozowana.

Model	**Typ**	R^2 **Score**	**RMSE**	**MAE**
XGBoost	Drzewa/Ensemble	0.8840	0.7019	0.4924
MLP (Deep)	Sieć Neuronowa	0.8827	0.7060	0.4834
MLP (Simple)	Sieć Neuronowa	0.8731	0.7340	0.5360
Random Forest	Drzewa/Ensemble	0.8611	0.7680	0.5088
Linear Regression	Liniowy	0.6786	1.1684	0.8714
Ridge Regression	Liniowy	0.6785	1.1685	0.8715

Tabela 7: *Zestawienie wyników modeli na zbiorze testowym (2018–2024)*

Analiza wyników wskazuje na wyraźną przewagę modeli nieliniowych nad liniowymi. Regresja liniowa i grzbietowa osiągnęły współczynnik R^2 na poziomie około 0.68, co wyznacza ograniczenia metod zakładających prostą, addytywną strukturę zależności. Zastosowanie algorytmów nieliniowych przyniosło wzrost jakości predykcji o blisko 20%, potwierdzając złożony charakter relacji między wskaźnikami makroekonomicznymi a poziomem przestrzegania praw człowieka.

Najlepsze wyniki uzyskał algorytm XGBoost, osiągając najwyższy współczynnik determinacji ($R^2 = 0.8840$) oraz najniższą wartość RMSE (0.7019), co wskazuje na wysoką skuteczność techniki boostingu w redukcji dużych błędów predykcyjnych. Bardzo zbliżoną efektywność wykazała głęboka sieć neuronowa (MLP Deep) z wynikiem $R^2 = 0.8827$, przy czym model ten uzyskał najniższą wartość MAE (0.4834), co oznacza największą dokładność w ujęciu przeciętnego błędu. Różnice między wersją prostą i głęboką sieci neuronowej potwierdzają znaczenie wielowarstwowej architektury w modelowaniu złożonych procesów geopolitycznych.

Uzyskane wartości błędów dla najlepszych modeli należy uznać za bardzo satysfakcjonujące. Średni błąd bezwzględny na poziomie 0.48–0.49 punktu skali wolności świadczy o wysokiej precyzji predykcji, szczególnie w kontekście danych testowych obejmujących okresy zwiększonej niestabilności geopolitycznej. Dla porównania modele liniowe charakteryzowały się średnim błędem zbliżonym do 0.9 punktu, co ograniczało ich użyteczność analityczną.

Konkludując przeprowadzone eksperymenty, jako model finalny do dalszych analiz wybrano XGBoost. Decyzja ta została podyktowana nie tylko najlepszymi wynikami w kluczowych metrykach R^2 i RMSE, ale również charakterystyką tego algorytmu w pracy z danymi tabelarycznymi. XGBoost wykazuje większą stabilność numeryczną niż sieci neuronowe oraz oferuje wbudowane mechanizmy oceny istotności cech, co jest kluczowe dla interpretacji uzyskanych wyników i zrozumienia czynników kształtujących wolność na świecie.

Rekonstrukcja cech i optymalizacja struktury danych dla modelu nieliniowego

Wybór algorytmu XGBoost jako modelu wiodącego umożliwił ponowną ocenę decyzji podjętych na etapie przetwarzania danych, które wcześniej były determinowane ograniczeniami modeli liniowych. Kluczowym elementem tej fazy było przywrócenie zmiennej `country_profile1`, usuniętej wcześniej ze względu na wysoki wskaźnik VIF. Decyzja ta wynika z odmiennych zasad działania algorytmów gradientowego wzmacniania drzew w porównaniu do klasycznej regresji liniowej.

Modele drzewiaste wykazują naturalną odporność na współliniowość, ponieważ proces uczenia opiera się na sekwencyjnym podziale przestrzeni cech z wykorzystaniem jednej zmiennej w danym węźle drzewa. W przypadku silnie skorelowanych predyktorów algorytm wybiera zmienną zapewniającą nieznacznie lepszą separację danych, pomijając pozostałe bez ryzyka niestabilności estymatorów. Co istotne, skorelowane cechy mogą nadal wnosić unikalną informację, która bywa wykorzystywana w głębszych strukturach drzewa, prowadząc do poprawy jakości predykcji.

Równolegle z rekonstrukcją zbioru cech zrezygnowano z etapu standaryzacji danych wejściowych. Algorytmy drzewiaste są niewrażliwe na skalę zmiennych, gdyż ich mechanizm decyzyjny opiera się na progach typu $x > próg$, a nie na miarach odległości czy iloczynach skalarnych. W efekcie model pozostaje niewrażliwy na różne skale zmiennych, eliminując potrzebę ich standaryzacji. Zastosowanie surowych wartości zmiennych zwiększa również interpretowalność modelu, umożliwiając bezpośrednie odniesienie wyników analizy ważności cech do oryginalnych jednostek, takich jak dolary amerykańskie, lata edukacji czy odsetek populacji.

Optymalizacja hiperparametrów modelu

Po wyborze algorytmu XGBoost jako modelu o najwyższym potencjale predykcyjnym kluczowym etapem stało się precyzyjne dostrojenie jego hiperparametrów w celu zapewnienia wysokiej zdolności generalizacji. Proces ten przeprowadzono z wykorzystaniem środowiska Optuna, opartego na bayesowskiej optymalizacji hiperparametrów. Dzięki algorytmowi TPE (*Tree-structured Parzen Estimator*) przestrzeń poszukiwań była adaptacyjnie zawężana do obszarów przynoszących najlepsze wyniki, co umożliwiło efektywne odnalezienie konfiguracji bliskiej optimum przy ograniczonym koszcie obliczeniowym.

Istotnym elementem procedury była walidacja czasowa (*TimeSeriesSplit*), dostosowana do charakteru danych panelowych obejmujących te same kraje w kolejnych latach. Zastosowanie losowego podziału danych prowadziłoby do wycieku informacji i nierealistycznej oceny jakości modelu. Metoda rozszerzającego się okna treningowego pozwoliła na wierną symulację procesu prognozowania, w którym model każdorazowo uczony był wyłącznie na danych historycznych, a testowany na kolejnych okresach.

Proces strojenia oparto na celowo dobranych zakresach hiperparametrów, ukierunkowanych na kontrolę złożoności modelu. Parametr *max_depth* ograniczono do przedziału 4–8, co zmusza algorytm do uczenia się globalnych zależności zamiast nadmiernie szczegółowych reguł. Dodatkowo parametr *min_child_weight* (5–15) zapobiegał tworzeniu podziałów opartych na zbyt małej liczbie obserwacji, wzmacniając statystyczną wiarygodność decyzji modelu.

W samym procesie uczenia zastosowano strategię *Slow Learning*, łącząc dużą liczbę drzew (*n_estimators*, 200–2000) z niskim współczynnikiem uczenia (*learning_rate*, 0.001–0.3). Takie podejście sprzyja stabilności predykcji poprzez stopniowe korygowanie błędów. Równocześnie wprowadzono losowość za pomocą parametrów *subsample* oraz *colsample_bytree* (0.6–1), co ogranicza dominację pojedynczych silnych zmiennych i zwiększa odporność modelu na anomalie danych.

Dodatkową ochronę przed przeuczeniem zapewniły mechanizmy regularyzacyjne oraz przycinanie drzew. Parametry *reg_alpha* (L1) i *reg_lambda* (L2) ograniczały nadmierne wartości wag, natomiast parametr *gamma* wymuszał minimalny zysk informacyjny konieczny do wykonania kolejnego podziału. W efekcie model zachowuje jedynie te reguły decyzyjne, które wnoszą istotną informację o badanym zjawisku.

Proces optymalizacji obejmujący 200 iteracji Optuny doprowadził do uzyskania modelu o bardzo wysokiej jakości predykcyjnej, co potwierdzają wyniki uzyskane na zbiorach walidacyjnym i testowym. Szczegółowe wartości dobranych hiperparametrów oraz końcowe metryki jakości zaprezentowano w Tabelach 8 i 9.

Hiperparametr	Wartość
n_estimators	1839
learning_rate	0.0298
max_depth	8
min_child_weight	10
subsample	0.8429
colsample_bytree	0.6051
reg_alpha	0.0002
reg_lambda	0.0003
gamma	0.0066

Tabela 8: *Zoptymalizowane hiperparametry modelu XGBoost*

Metryka	Walidacja	Test
R^2 Score	0.9319	0.9235
RMSE	—	0.5699
MAE	—	0.3898

Tabela 9: *Porównanie metryk jakości modelu*

Średnia wartość współczynnika determinacji uzyskana w walidacji krzyżowej wyniosła $R^2 = 0.9319$, natomiast na zbiorze testowym osiągnięto 0.9235. Niewielki spadek jakości świadczy o dobrej generalizacji modelu i braku przeuczenia. To szczególnie istotne, biorąc pod uwagę, że zbiór testowy obejmuje lata 2019–2024, charakteryzujące się silnymi zakłóceniami geopolitycznymi i gospodarczymi (pandemia COVID-19). Model zachował wysoką skuteczność, opierając prognozy na regułach wyuczonych w bardziej stabilnych okresach.

Analiza konfiguracji wyłonionej przez Optunę dostarcza dodatkowych wniosków o naturze badanego zjawiska. Bardzo duża liczba drzew (1839) przy niskim współczynniku uczenia (ok. 0.03) potwierdza zasadność strategii powolnego budowania wiedzy. Maksymalna głębokość drzewa ($max_depth = 8$) wskazuje na wielopoziomowy charakter zależności kształtujących poziom wolności, natomiast wysoka wartość *min_child_weight* (10) skutecznie ograniczała tworzenie reguł opartych na przypadkowych, małych podzbiorach danych.

Istotnym elementem okazała się również agresywna dywersyfikacja cech — model wykorzystywał około 60% zmiennych przy budowie pojedynczego drzewa, co zwiększyło jego odporność i wymusiło korzystanie z różnych źródeł informacji. Niska rola regularyzacji matematycznej sugeruje, że same ograniczenia strukturalne były wystarczające do kontroli złożoności modelu. Ostatecznie niski błąd MAE na poziomie 0.39 punktu skali wskaźnika wolności potwierdza wysoką precyzję predykcji i użyteczność modelu w analizach scenariuszowych oraz badaniach nad przyszłością systemów demokratycznych.

Wyniki

Diagnostyka procesu optymalizacji

Wyłonienie optymalnego zestawu parametrów strukturalnych nie jest wystarczające do pełnej walidacji modelu predykcyjnego. W nurcie odpowiedzialnego uczenia maszynowego niezbędna jest szczegółowa weryfikacja przebiegu samego procesu poszukiwań, która pozwala upewnić się, że algorytm TPE (*Tree-structured Parzen Estimator*) faktycznie zbiegł do globalnego optimum, a nie został uwięziony w minimum lokalnym. Diagnostyka ta pozwala również ocenić, czy przyjęte zakresy przestrzeni hiperparametrów były właściwie zdefiniowane.

Analiza wrażliwości hiperparametrów

Pierwszym etapem diagnostyki była analiza ważności hiperparametrów, określająca ich wpływ na końcową wartość współczynnika determinacji R^2. Wykres przedstawiony na Figurze 20 ujawnia silną koncentrację istotności, aż 89% zmienności wyników było determinowane przez parametr *gamma*. Jako próg minimalnej redukcji straty wymaganej do wykonania kolejnego podziału, parametr ten pełnił kluczową rolę regularyzacyjną. Pozostałe hiperparametry miały marginalny wpływ w analizowanym zakresie.

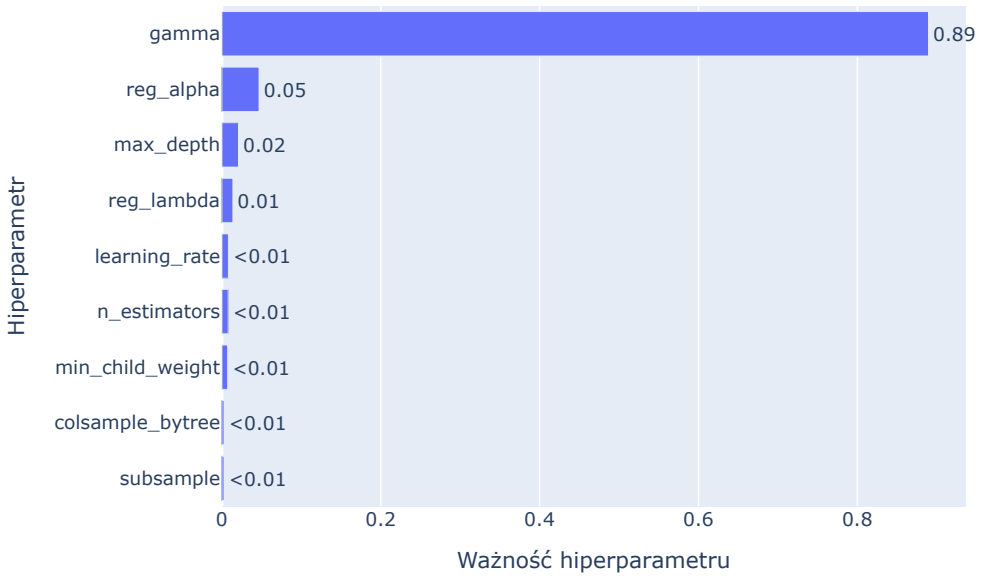

Rysunek 20: *Wykres ważności hiperparametrów modelu XGBoost wyznaczony metodą TPE*

Taki rozkład wskazuje na istnienie krytycznego progu intensywności przycinania drzew. Zbyt wysokie wartości *gamma* prowadziły do nadmiernego upraszczania struktury modelu, natomiast po osiągnięciu optymalnego poziomu regularyzacji następował skokowy wzrost jakości predykcji. Drugorzędna rola pozostałych parametrów stanowi korzystny sygnał stabilności modelu, po ustaleniu właściwego poziomu regularyzacji jego skuteczność okazała się odporna na drobne zmiany architektury i tempa uczenia. Osiągnięcie $R^2 > 0.92$ było zatem przede wszystkim wynikiem trafnego balansu między eliminacją szumu statystycznego a zachowaniem istotnych sygnałów makroekonomicznych, który algorytm Optuna skutecznie odnalazł.

Analiza przebiegu optymalizacji

Drugim kluczowym elementem diagnostyki była analiza przebiegu optymalizacji, która pozwoliła ocenić dynamikę zbieżności algorytmu bayesowskiego (Rysunek 21). Rozkład kolejnych prób (niebieskie punkty) oraz przebieg najlepszego dotychczasowego wyniku (czerwona linia) ujawniają trzy wyraźne fazy procesu. W pierwszej, obejmującej iteracje 0–55, dominuje intensywna eksploracja przestrzeni hiperparametrów, charakteryzująca się wysoką wariancją funkcji celu ($R^2 \approx 0.83$–0.92). Etap ten umożliwił szybkie zidentyfikowanie obszaru o wysokiej jakości rozwiązań i ustanowienie punktu odniesienia dla dalszych poszukiwań.

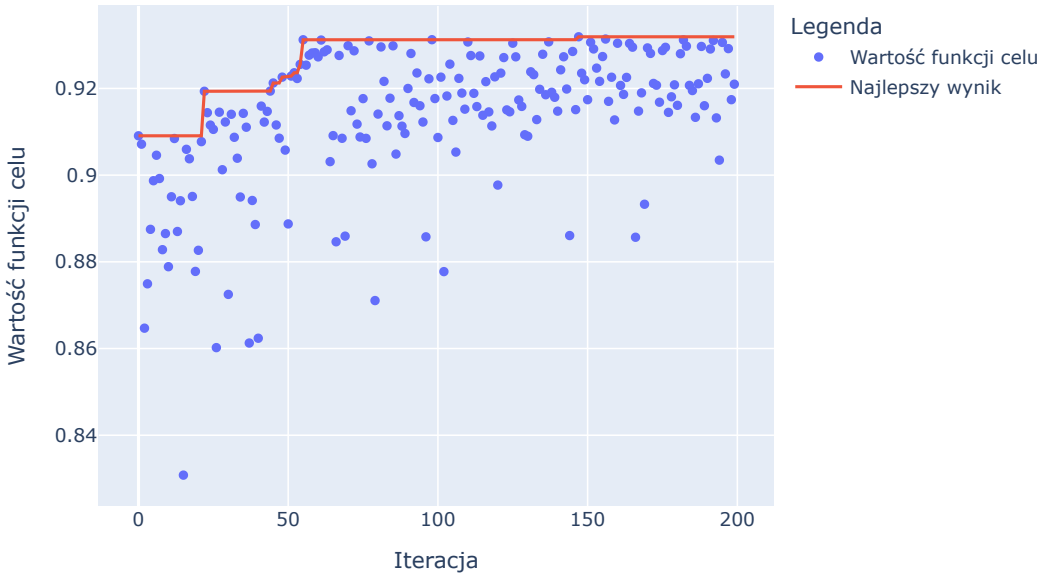

Rysunek 21: *Przebieg procesu optymalizacji hiperparametrów w bibliotece Optuna*

Druga faza (iteracje 56–146) odpowiada etapowi eksploatacji i lokalnej stabilizacji rozwiązania. Pomimo braku dalszego wyraźnego wzrostu najlepszego wyniku, wysoka gęstość prób w górnym zakresie wykresu wskazuje na systematyczne przeszukiwanie otoczenia optimum w celu redukcji niepewności estymacji. Przełom nastąpił w okolicach 147. iteracji, gdzie odnotowano niewielką, lecz istotną poprawę jakości predykcji. Zjawisko to stanowi empiryczne potwierdzenie skuteczności metod bayesowskich, które potrafią identyfikować wąskie nisze konfiguracyjne, w tym przypadku prawdopodobnie wynikające z precyzyjnego zestrojenia głębokości drzew z parametrem *gamma*.

Płaski charakter linii w końcowej fazie (iteracje 150-200) sugeruje osiągnięcie asymptoty wydajności modelu na dostępnych danych wejściowych. Dalsze zwiększanie liczby prób prawdopodobnie nie przyniosłoby już mierzalnego wzrostu jakości, gdyż ograniczeniem stała się informacyjność samych cech, a nie konfiguracja algorytmu XGBoost. Tym samym zbiór parametrów wyłoniony w 147. iteracji uznaje się za ostateczny i w pełni zwalidowany pod kątem stabilności numerycznej.

Ocena i interpretacja modelu predykcyjnego

Czynniki kształtujące poziom wolności - analiza SHAP

Wysoka skuteczność predykcyjna modelu ($R^2 > 0.92$) wymaga uzupełnienia o analizę mechanizmów decyzyjnych. W tym celu zastosowano metodę SHAP, opartą na teorii gier kooperacyjnych, która przypisuje każdej zmiennej wkład liczbowy określający jej wpływ na odchylenie predykcji modelu od wartości bazowej.

Szczegółowa analiza hierarchii czynników

Globalną ważność cech oceniono na podstawie średnich wartości bezwzględnych SHAP (Tabela 10). Ranking ujawnia wyraźną dominację zmiennych syntetycznych opartych na PCA.

Cecha	**Średni wpływ**	**Cecha**	**Średni wpływ**
`country_profile1`	0.6172	`region_LAC`	0.0505
`country_profile3`	0.3569	`mean_school`	0.0446
`old_age`	0.2928	`sex_ratio`	0.0367
`gdp_pc`	0.1239	`fertility_rate`	0.0305
`country_profile2`	0.1182	`region_AFR`	0.0216
`country_profile4`	0.1137	`region_CPA`	0.0189
`region_MEA`	0.1043	`region_EEU`	0.0161
`imr_value`	0.0942	`region_WEU`	0.0066
`country_profile5`	0.0832	`region_PAS`	0.0054
`p_density`	0.0778	`region_SAS`	0.0028
`net_migration`	0.0772	`region_PAO`	0.0001
`region_FSU`	0.0642	`region_NAM`	0.0000
`avg_temp`	0.0541		

Tabela 10: *Ranking globalnej ważności cech (średnie wartości absolutne SHAP)*

Najsilniejszym predyktorem okazał się *country_profile1* (Profil Rozwoju Społeczno-Ekonomicznego), integrujący informacje o poziomie edukacji, PKB per capita, strukturze wieku oraz zdrowiu populacji. Jego wysoki wpływ potwierdza kluczową rolę długookresowej dojrzałości instytucjonalnej i społecznej w kształtowaniu poziomu wolności.

Drugim czynnikiem jest *country_profile3* (Niestabilność Gospodarczo-Zdrowotna), którego znaczenie wskazuje, że zmienność warunków bytowych i zdrowotnych działa silnie destabilizująco na wolność polityczną, niezależnie od średniego poziomu rozwoju. Jednoczesna dominacja dwóch profili krajowych wskazuje na wysoką ciągłość systemów politycznych oraz istotny wpływ uwarunkowań historycznych na poziom wolności.

Wśród zmiennych bazowych wyróżnia się struktura wieku społeczeństwa (*old_age*), której wpływ przewyższa znaczenie PKB per capita. Sugeruje to, że dojrzałość demograficzna jest lepszym wskaźnikiem stabilności instytucjonalnej niż sama zamożność. Czynniki regionalne, zwłaszcza *region_MEA*, wnoszą dodatkową korektę geopolityczną, niewyjaśnianą wyłącznie zmiennymi ekonomicznymi.

Kierunkowość wpływu cech

Rozkłady wartości SHAP (Rys. 22) pokazują asymetrię i kierunek wpływu zmiennych.

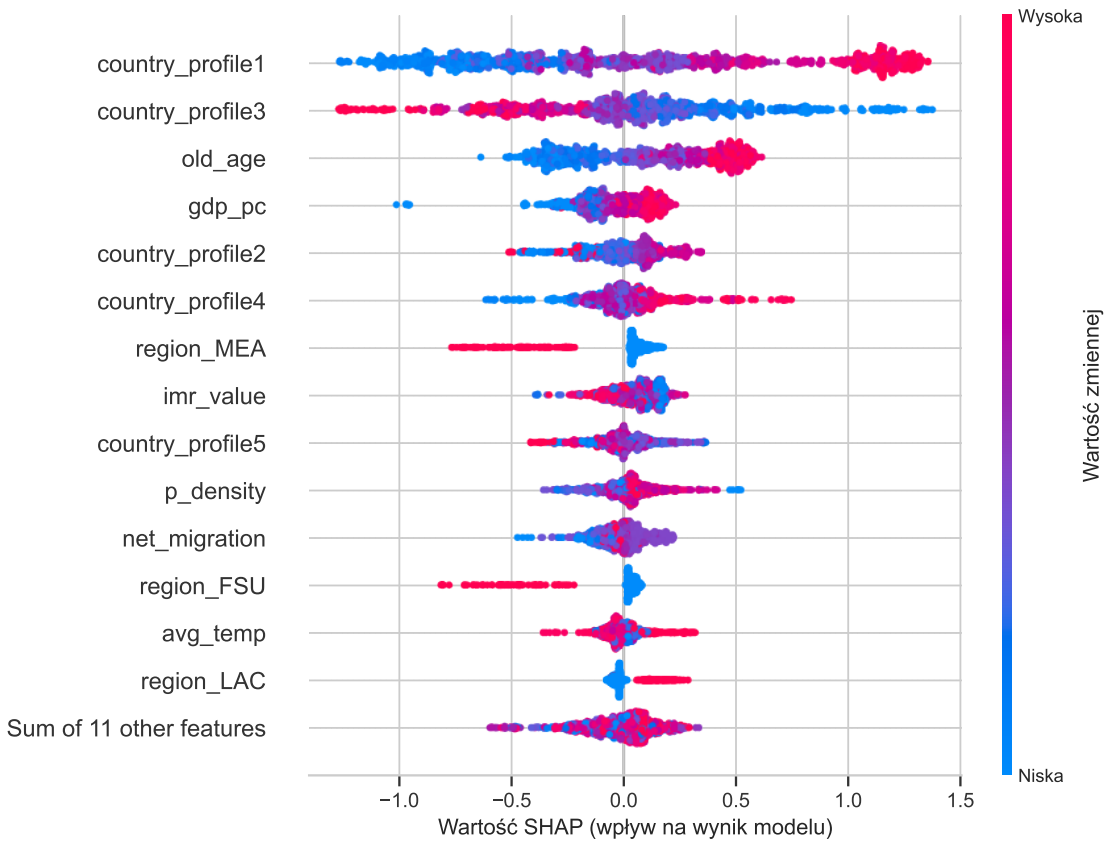

Rysunek 22: *Wykres rozkładu wartości SHAP dla najważniejszych cech modelu*

Profile syntetyczne oparte na PCA (*country_profile1* i *country_profile3*) wykazują szeroki, symetryczny zakres wpływu, działając jako główne osie pozycjonujące państwa na skali wolności. Wysokie wartości profilu rozwoju systematycznie zwiększają predykcję, natomiast wysoka niestabilność gospodarczo-zdrowotna prowadzi do jej gwałtownych spadków.

PKB per capita charakteryzuje się silną asymetrią: niski poziom rozwoju znacząco obniża poziom wolności, podczas gdy jego wzrost generuje jedynie umiarkowane korzyści. Wskazuje to na rolę ekonomii jako czynnika ograniczającego, a nie automatycznego motoru demokratyzacji.

Zmienne regionalne, szczególnie *region_FSU* (były Związek Radziecki) oraz *region_MEA* (Bliski Wschód i Afryka Północna), działają niemal wyłącznie negatywnie, tworząc trwałe bariery strukturalne dla wzrostu wolności. Odmienny charakter ma demografia, zmienna *old_age* wykazuje stabilny, dodatni wpływ przy relatywnie niskiej wariancji.

Analiza wskazuje, że poziom wolności jest silnie uwarunkowany długookresowymi cechami państw oraz podatny na nagłe pogorszenia w wyniku kryzysów gospodarczych i geopolitycznych. Poprawa zachodzi stopniowo i rzadko ma charakter gwałtowny. Profile państw wyodrębnione metodą PCA umożliwiają uchwycenie tych trwałych zależności.

Weryfikacja dopasowania modelu

Jakość dopasowania modelu oceniono na podstawie wykresu zależności pomiędzy wartościami rzeczywistymi a prognozami (Rysunek 23). Analiza ta umożliwia ocenę poprawności predykcji.

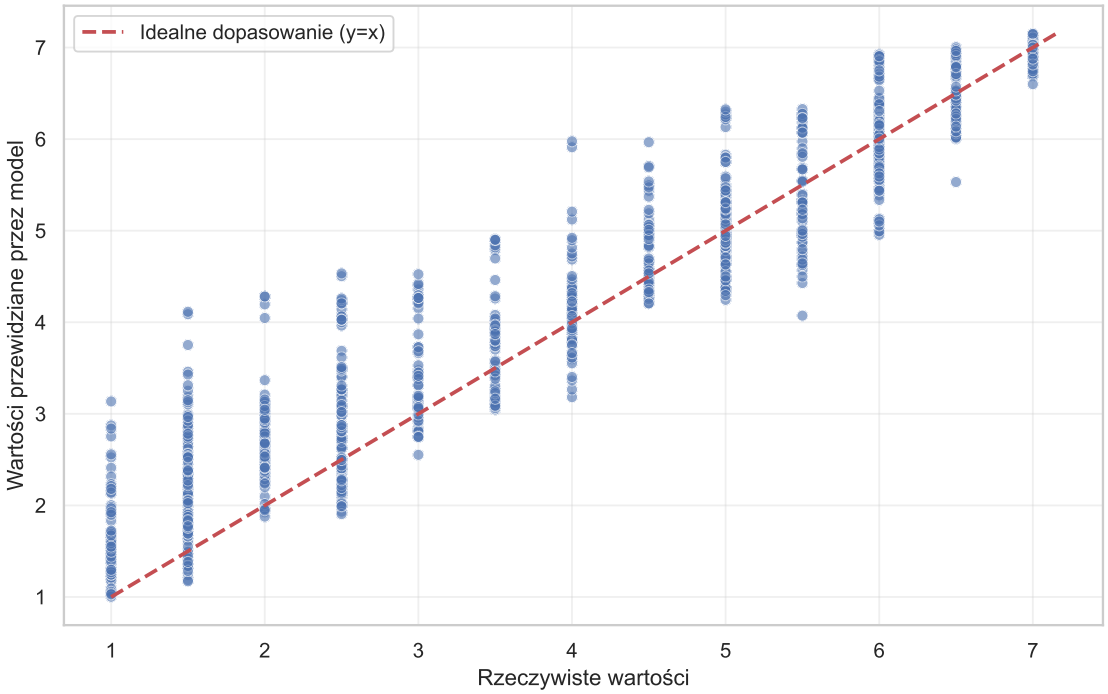

Rysunek 23: *Porównanie wartości rzeczywistych i predykcji modelu XGBoost*

Na podstawie rozmieszczenia punktów względem linii idealnego dopasowania (y=x) można wyróżnić trzy charakterystyczne zakresy funkcjonowania modelu, różniące się zarówno kierunkiem, jak i wielkością błędów predykcji.

Zakres wartości niskich i średnich (1.0–4.5)
W tej części skali model wykazuje wyraźną tendencję do przeszacowywania wyników. Predykcje są zazwyczaj wyższe od wartości rzeczywistych, natomiast przypadki niedoszacowania występują sporadycznie. Jednocześnie w tym przedziale obserwowane są największe błędy predykcji, w skrajnych przypadkach model zawyża wynik nawet o około 2 punkty. Sugeruje to, że czynniki społeczno-gospodarcze wskazują na wyższy potencjał swobód niż obserwowany w praktyce.

Zakres wartości wysokich (5.0–6.5)
W tym przedziale charakter błędów ulega wyraźnej zmianie. Predykcje koncentrują się bliżej linii referencyjnej, a rozkład błędów staje się bardziej symetryczny, występują zarówno przeszacowania, jak i niedoszacowania. Jednocześnie ich amplituda jest mniejsza i zazwyczaj nie przekracza 1 punktu.

Wartość maksymalna (7.0)
Dla państw osiągających najwyższy poziom wolności model cechuje się największą dokładnością, co oznacza, że cechy strukturalne stabilnych demokracji są rozpoznawane najskuteczniej. Błąd predykcji jest niewielki i zwykle nie przekracza 0.5 punktu. Należy jednak zaznaczyć, że pojawiają się również przewidywania nieco wyższe niż maksymalny możliwy poziom wolności, co sugeruje lekką tendencję modelu do przeceniania cech stabilnych demokracji.

Podsumowując, model najlepiej identyfikuje państwa o wysokim poziomie wolności. W górnym zakresie skali osiąga umiarkowaną precyzję przy względnie losowym rozkładzie błędów, natomiast w dolnej i środkowej części ujawnia systematyczną tendencję do zawyżania poziomu wolności, co może wynikać z pozastrukturalnej natury systemów autorytarnych.

Case Study → analiza największego błędu predykcyjnego

W celu pełnego zrozumienia ograniczeń modelu w wykrywaniu gwałtownych regresji demokratycznych przeanalizowano przypadek z największym błędem predykcji (Index 1092), Nikaraguę w 2023 roku. Rzeczywisty wskaźnik wolności wynosił 1.50 (dyktatura), podczas gdy model przewidział 4.11 (kraj częściowo wolny). Analiza wykresu kaskadowego (Rysunek 24) pozwala dokładnie wskazać przyczyny tego rozbiegu.

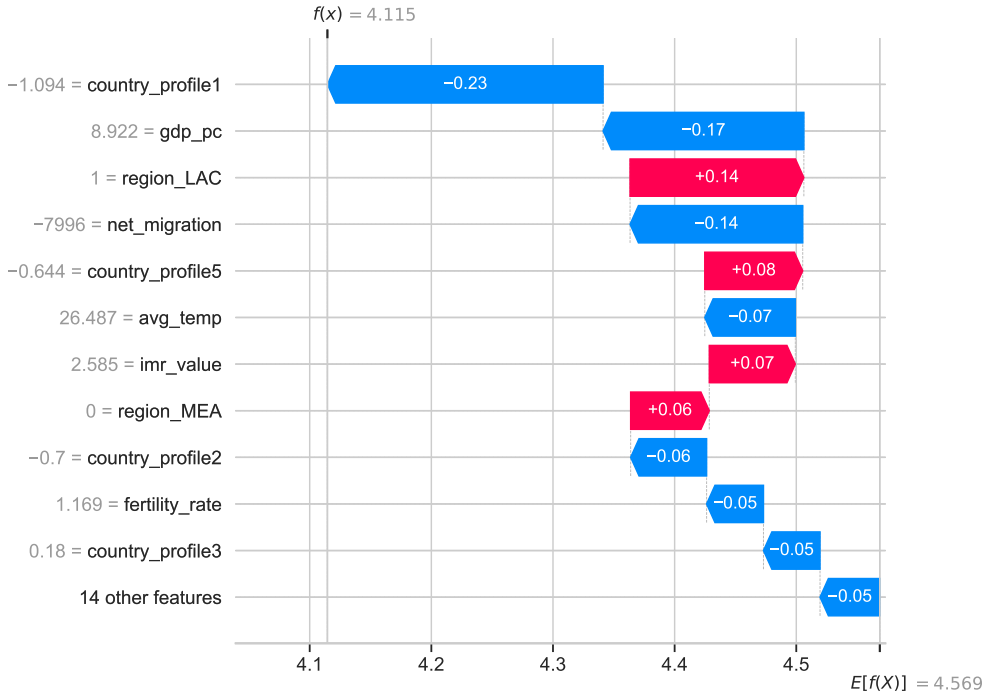

Rysunek 24: *Wykres dekompozycji czynników wpływających na prognozę wskaźnika wolności dla Nikaragui*

Analizę należy rozpocząć od wartości bazowej $E[f(X)] = 4.569$, reprezentującej średnią predykcję modelu dla wszystkich krajów. To punkt wyjściowy, który model przypisałby Nikaragui przy braku dodatkowych informacji. Kolejne czynniki (słupki czerwone i niebieskie) przesuwają tę wartość w górę lub w dół, aż do ostatecznej prognozy $f(x) = 4.115$.

Pierwszym czynnikiem jest tzw. pułapka „dobrego sąsiedztwa" (*region_LAC*, +0.14), wynikająca z faktu, że statystycznie region Ameryki Łacińskiej obejmuje głównie wadliwe demokracje, a nie twarde autokracje. Model potraktował Nikaraguę jako anomalię wobec sąsiadów, nie uwzględniając jej unikalnej trajektorii.

Kolejny błąd wynika z danych historycznych (*country_profile1*, −0.23), które nie odzwierciedlały gwałtownego przyspieszenia autorytaryzmu po 2018 roku. Model oparty na trendach historycznych nie jest w stanie odpowiednio reagować na nagłe zmiany polityczne.

Ostatni element to rozbieżność między kondycją socjoekonomiczną a polityczną. Relatywnie stabilne wskaźniki, jak niska śmiertelność niemowląt (*imr_value*, +0.07) i umiarkowana migracja (−0.14), sugerowały umiarkowaną wolność, mimo nasilonych represji politycznych.

Podsumowując, przypadek Nikaragui ujawnia główną słabość modeli opartych wyłącznie na danych tabelarycznych. Oceniają one dobrze długofalowe fundamenty państwa, lecz nie uwzględniają nagłych zwrotów autorytarnych, dopóki ich skutki nie zostaną odzwierciedlone w twardych wskaźnikach makroekonomicznych.

Predykcja długookresowa

Na podstawie wytrenowanego modelu XGBoost przeprowadzono predykcję wskaźnika wolności osobno dla każdego z trzech scenariuszy SSP. Weryfikacja dopasowania na danych treningowych wykazała niewielką tendencję do przewyższania maksymalnej skali wskaźnika wolności, co wynika z charakteru modelu regresyjnego, który nie posiada wbudowanych ograniczeń zakresu wartości wyjściowych. Analiza danych predykcyjnych wykazała, że minimalne wartości mieściły się w granicach skali (1.2–1.4), natomiast przypadki przewyższenia górnego zakresu (7.0) oraz ich udział procentowy przedstawiono w Tabeli 11. Ze względu na to, że przekroczenia mieszczą się w granicach błędu predykcji modelu i mają marginalną skalę, zdecydowano się na obcięcie ich do maksymalnej dopuszczalnej wartości wskaźnika.

Scenariusz	**Udział przewyższeń skali**	**Maksymalna wartość**
SSP1	1.11%	7.13
SSP2	6.90%	7.18
SSP3	4.75%	7.14

Tabela 11: *Analiza przekroczeń górnego zakresu wskaźnika wolności*

Harmonizacja danych

Zweryfikowano spójność pomiędzy danymi historycznymi kończącymi się w 2024 roku a prognozami opartymi na scenariuszach SSP rozpoczynającymi się od 2025 roku. Analiza ujawniła istotną nieciągłość na styku obu zbiorów, przejawiającą się skokową zmianą wartości wskaźnika wolności w roku 2025 względem roku 2024, niezależnie od analizowanego scenariusza. Zjawisko to nie odzwierciedla rzeczywistej poprawy sytuacji geopolitycznej, lecz stanowi artefakt metodologiczny wynikający z charakteru modeli SSP, które bazują na długookresowych trendach strukturalnych i nie uwzględniają krótkoterminowych szoków oraz fluktuacji obecnych w danych empirycznych z 2024 roku.

W konsekwencji prognozy SSP rozpoczynają się z poziomu teoretycznego, niespójnego z rzeczywistym punktem startowym, co bez korekty prowadziłoby do błędnych wniosków o nagłym wzroście poziomu wolności. W celu zapewnienia ciągłości szeregu czasowego i zachowania interpretacyjnej poprawności wyników zastosowano procedurę harmonizacji danych. Polegała ona na obliczeniu różnicy pomiędzy ostatnią obserwacją historyczną i pierwszą prognozowaną, a następnie przesunięciu całego prognozowanego zbioru o tę stałą wartość. Zabieg ten pozwolił na wyrównanie początkowego poziomu prognozy przy jednoczesnym zachowaniu oryginalnej dynamiki oraz nachylenia trendu wynikającego z założeń scenariuszy SSP. Skorygowana prognoza została scalona z danymi historycznymi w jeden szereg panelowy.

Analiza prognozy modelu na świecie

W tej sekcji przedstawiono prognozy średniego poziomu wskaźnika wolności na świecie (Rysunek 25). Na wykresie przedstawiono zarówno przewidywane wyniki, jak i przedziały ufności oparte na średnim błędzie bezwzględnym modelu (MAE = 0.3898), które wskazują, w jakim przedziale najprawdopodobniej znajdą się rzeczywiste wartości.

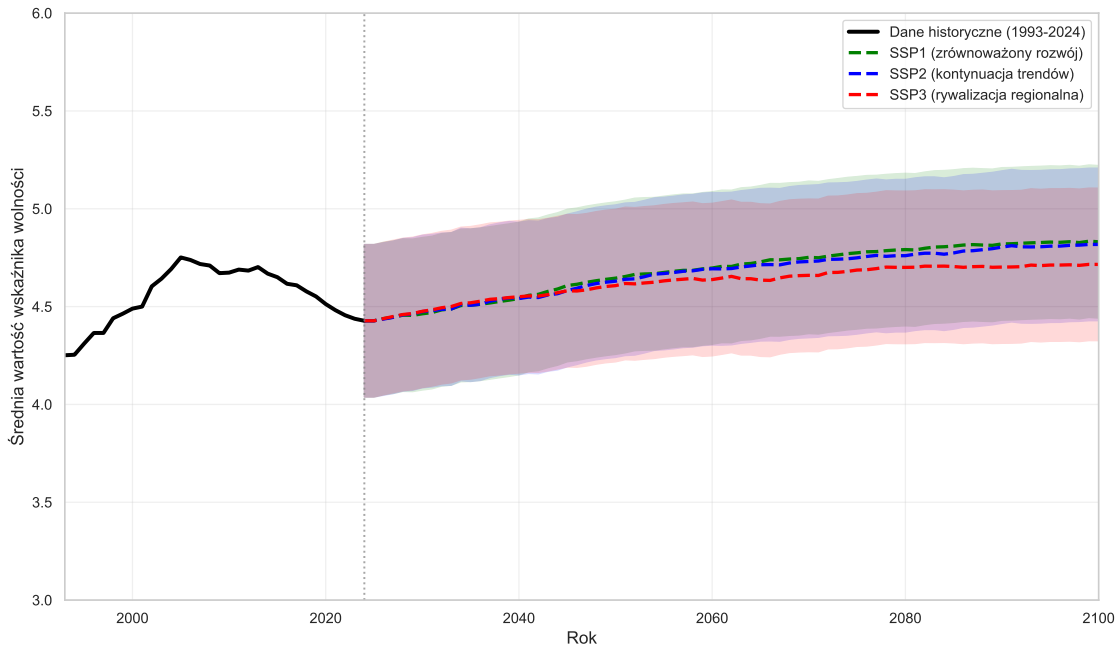

Rysunek 25: *Prognoza średniej światowej wartości wskaźnika wolności w horyzoncie czasowym do 2100 roku, opracowana dla scenariuszy SSP1, SSP2 oraz SSP3*

W latach 2025–2045 wszystkie analizowane scenariusze charakteryzują się niemal identycznym przebiegiem oraz łagodnym trendem wzrostowym. Świadczy to o dominującym wpływie obecnych uwarunkowań strukturalnych i ograniczonym znaczeniu różnic zapisanych w założeniach scenariuszy SSP.

Po upływie połowy stulecia obserwowane jest stopniowe rozchodzenie się trajektorii prognoz, będące efektem kumulacji różnic w tempie rozwoju gospodarczego, poziomie edukacji oraz stabilności demograficznej. Scenariusze SSP1 i SSP2 pozostają do siebie bardzo zbliżone i wykazują umiarkowanie dodatnią dynamikę. Odmiennie kształtuje się scenariusz SSP3, w którym po 2060 roku dynamika wzrostu wyraźnie słabnie, a wartości wskaźnika stabilizują się, wskazując na istnienie strukturalnych ograniczeń wzrostu wolności.

Należy jednak podkreślić, że maksymalne różnice pomiędzy scenariuszami nie przekraczają około 0,1 punktu wskaźnika. Oznacza to, że w skali globalnej poziom wolności pozostaje relatywnie stabilny, oscyluje wokół wartości historycznych (około 4.5) i nie jest silnie uzależniony od przyjętej ścieżki rozwoju.

Analiza prognozy wskaźnika wolności w Ugandzie

Analiza prognoz dla Ugandy (Rysunek 26) ukazuje wyraźnie większą dynamikę i zróżnicowanie scenariuszowe niż w przypadku średniej globalnej. Jednakże prognozowanie precyzyjnych wartości w 75-letnim horyzoncie czasowym wiąże się z wysokim ryzykiem błędu, wynikającym zarówno z ograniczeń modelu, jak i niepewności danych wejściowych. W celu lepszego zobrazowania przewidywanych zmian ustrojowych przyjęto trzy poziomy wolności: kraj wolny (wynik ≥ 5.25), częściowo wolny (wynik ≥ 2.75) oraz niewolny (wynik < 2.75).

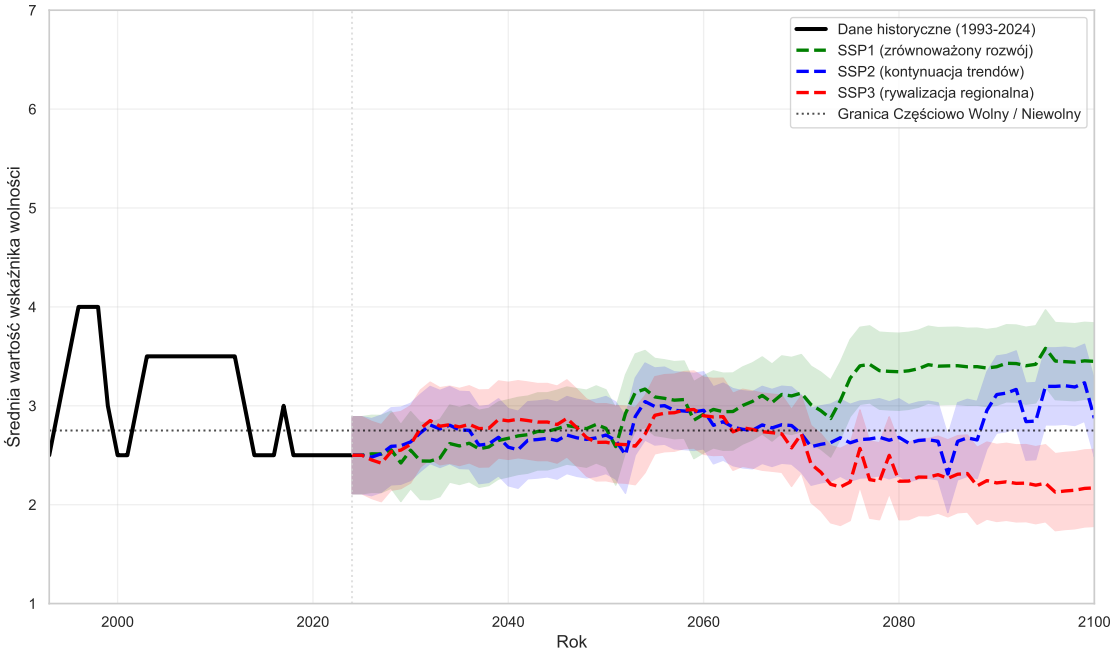

Rysunek 26: *Prognoza wartości wskaźnika wolności w Ugandzie do 2100 roku, opracowana dla scenariuszy SSP1, SSP2 oraz SSP3*

Uganda rozpoczyna okres prognozy z niskim wskaźnikiem wolności (2.5), co klasyfikuje ją jako kraj niewolny. Dane historyczne wykazują dużą zmienność i brak trwałego trendu wzrostowego.

Przez pierwsze trzy dekady przewidywane wartości oscylują na granicy kategorii kraju częściowo wolnego i niewolnego, jednak w drugiej połowie stulecia następuje wyraźne rozwidlenie ścieżek rozwoju. Scenariusz SSP1 daje nadzieję na przełom, około 2075 roku zarówno prognozowana wartość, jak i zakres błędu MAE w całości mieszczą się w przedziale kraju częściowo wolnego. Z kolei scenariusz SSP3 ostrzega przed degradacją ustrojową, po 2080 roku nawet górna granica błędu MAE nie przekracza już progu częściowej wolności, co sugeruje utrwalenie statusu autorytarnego. Scenariusz SSP2 reprezentuje wariant pośredni, w którym państwo pozostaje w zawieszeniu między obiema kategoriami.

Analiza potwierdza czułość modelu na parametry różnicujące scenariusze SSP, szczególnie w krajach o niskiej odporności systemowej. Wyniki te dowodzą zdolności modelu do identyfikacji punktów zwrotnych, w których ścieżki rozwoju zaczynają się od siebie gwałtownie oddalać pod wpływem przyjętych warunków brzegowych.

Trajektorie zmian statusu wolności w długookresowych prognozach

Prognozowanie przestrzegania praw człowieka w 193 państwach w horyzoncie kolejnych 75 lat jest zadaniem o wysokim stopniu złożoności. W celu usystematyzowania analizy ocenę ewolucji oparto na trzech zdefiniowanych wcześniej poziomach wolności. Do badania wybrano trzy punkty w szeregu czasowym, lata 2024, 2062 oraz 2100, które reprezentują odpowiednio początek, środek oraz koniec okresu prognozy. Taki dobór pozwala na uchwycenie dynamiki zmian statusu wolności oraz weryfikację trwałości trendów w długim okresie. Wiarygodność prognozowanych przejść między kategoriami oceniono poprzez uwzględnienie przedziałów niepewności opartych na średnim błędzie bezwzględnym modelu (MAE = 0.3898). Wyniki analizy dla państw, w których odnotowano zmiany statusu, przedstawiono w Załączniku A. Strzałki w tabeli wskazują kierunek, w jakim przedział niepewności predykcji może przekroczyć próg poziomu wolności. Dopełnieniem szczegółowych danych tabelarycznych jest mapa (Załącznik B), która obrazuje prognozowane zmiany poziomów wolności w 2100 roku względem stanu z 2024 roku. Na podstawie wyżej wymienionych załączników wyodrębniono cztery wnioski dotyczące długookresowych trendów w zakresie przestrzegania praw człowieka na świecie.

Pierwszym zidentyfikowanym trendem jest systematyczny spadek zasięgu obszarów o najniższym poziomie ochrony praw człowieka. Wyniki modelu wskazują na stopniowe wychodzenie z głębokiego autorytaryzmu, co jest szczególnie widoczne w regionie MENA (Bliski Wschód i Afryka Północna). Państwa takie jak Algieria, Bahrajn czy Syria, które w 2024 roku sklasyfikowano jako niewolne, szczególnie w scenariuszach SSP1 i SSP2 ewoluują w stronę kategorii „częściowo wolny". Choć proces ten nie jest tożsamy z pełną demokratyzacją, sugeruje on trwałą poprawę bezpieczeństwa prawnego i obywatelskiego napędzaną czynnikami demograficzno-gospodarczymi. Podobną dynamikę wykazuje Afryka Subsaharyjska, gdzie kraje takie jak Angola, Somalia czy Sudan wykazują potencjał do opuszczenia strefy najniższych wskaźników wolności do 2100 roku, przy czym tempo pozostaje uzależnione od realizacji założeń konkretnego scenariusza.

Kolejnym istotnym zjawiskiem jest prognozowana regresja standardów w państwach, które dotychczas charakteryzowały się wysokim poziomem ochrony praw człowieka. Najbardziej wyrazistym przykładem tego trendu jest Brazylia, która mimo wysokiego punktu wyjścia, we wszystkich analizowanych scenariuszach wykazuje tendencję spadkową, kończąc okres prognozy w kategorii kraju częściowo wolnego. Zjawisko to może świadczyć o wysokiej wrażliwości modelu na specyficzne wskaźniki strukturalne, które w długim terminie osłabiają mechanizmy ochrony obywatela przed nadużyciami władzy. Ryzyko obniżenia tych standardów odnotowano również w przypadku mniejszych organizmów państwowych, takich jak Wyspy Salomona czy Timor Wschodni, co sugeruje, że państwa te mogą cechować się wyższą podatnością na globalne wstrząsy przewidziane w scenariuszach.

Wyniki dla 2100 roku uwypuklają zjawisko radykalnego rozwarstwienie trajektorii rozwoju w zależności od przyjętego wariantu SSP. Scenariusz SSP1 (Zrównoważony rozwój) pełni funkcję katalizatora zmian pozytywnych, pozwalając państwom takim jak Albania czy Boliwia na trwałe umocnienie statusu krajów wolnych, przy jednoczesnym zachowaniu bezpiecznego marginesu błędu MAE względem progów kategorii. Przeciwwagę stanowi scenariusz SSP3 (Fragmentacja), będący wariantem stagnacji lub regresu. Na przykładzie Algierii widać, iż jest to jedyny scenariusz przewidujący powrót do stanu systemowych naruszeń praw człowieka po okresie przejściowej poprawy, co podkreśla krytyczne znaczenie stabilności ekonomicznej i współpracy międzynarodowej dla podtrzymania standardów ochrony jednostki.

Ostatnim kluczowym wnioskiem jest istnienie grupy państw odpornych na zmiany, których status pozostaje niewrażliwy na dobór scenariusza SSP. Przykładem takiej stabilizacji jest Tajlandia, która przez cały 75-letni okres prognozy utrzymuje status kraju częściowo wolnego. W tych przypadkach odnotowano stabilizację wskaźników na poziomie pośrednim, czynniki wprowadzone do modelu są wystarczające do uniknięcia regresji w stronę skrajnych naruszeń praw człowieka, ale jednocześnie nie pozwalają na osiągnięcie najwyższego poziomu ich ochrony.

Dyskusja

Przeprowadzone w niniejszej pracy badania nad wykorzystaniem uczenia maszynowego do analizy naruszeń praw człowieka pozwoliły na sformułowanie szeregu istotnych wniosków dotyczących natury procesów demokratyzacji oraz ograniczeń metod ilościowych w naukach społecznych. Osiągnięcie wysokiej skuteczności predykcyjnej przez model XGBoost ($R^2 > 0.92$ na zbiorze testowym) potwierdza, że poziom przestrzegania praw człowieka jest w dużej mierze skorelowany z mierzalnymi parametrami strukturalnymi. Jednakże głębsza analiza mechanizmów decyzyjnych modelu (metoda SHAP) oraz błędów predykcji ujawniają złożoną hierarchię czynników, w której bieżące wskaźniki rozwoju ustępują miejsca historycznym uwarunkowaniom państwa.

Kluczowym wnioskiem płynącym z analizy ważności cech jest przewaga zmiennych opisujących historię i strukturę państwa nad bieżącymi wskaźnikami makroekonomicznymi. Najsilniejszym predyktorem w modelu okazał się *country_profile1* (Profil Rozwoju Społeczno-Ekonomicznego), który agreguje historyczne dane na temat edukacji, zamożności i demografii.

Wynik ten sugeruje, że poziom wolności i praw człowieka charakteryzuje się znaczną inercją systemową. Systemy polityczne są efektem wieloletnich procesów akumulacji kapitału społecznego i instytucjonalnego. Oznacza to, że sama poprawa wskaźników ekonomicznych w krótkim horyzoncie czasowym ma ograniczony natychmiastowy wpływ na poziom wolności, jeśli nie towarzyszy jej długofalowa dojrzałość instytucjonalna. Proces uczenia modelu wykazał, że historyczna trajektoria państwa jest kluczowym prognostykiem jego przyszłości, co potwierdza zjawisko zależności od ścieżki. Wskaźniki rozwoju pełnią funkcję fundamentów, które wyznaczają potencjał dla praw człowieka, jednak to uwarunkowania historyczne determinują faktyczny stan swobód obywatelskich.

Istotnym ograniczeniem zaproponowanego podejścia, które obrazuje specyfikę modelowania zjawisk społecznych, jest przypadek Nikaragui w 2023 roku. Model odnotował w tym przypadku największy błąd predykcyjny, szacując wskaźnik na poziomie 4.11 (kraj częściowo wolny), podczas gdy wartość rzeczywista wynosiła 1.50 (kraj niewolny).

Szczegółowa analiza tego przypadku wskazuje, że model oparty na wskaźnikach społeczno-ekonomicznych identyfikuje przede wszystkim strukturalne trendy rozwoju, a nie nagłe zmiany polityczne wynikające z decyzji władz. W przypadku Nikaragui wskaźniki takie jak niska śmiertelność niemowląt czy umiarkowana migracja sugerowały relatywną stabilność. Model zinterpretował te dane jako sygnał, że państwo posiada fundamenty typowe dla „częściowo wolnych” demokracji regionu Ameryki Łacińskiej, ulegając zjawisku określanemu jako wpływ otoczenia regionalnego.

Prowadzi to do wniosku, że korzystna sytuacja społeczno-ekonomiczna może maskować procesy autorytaryzacji. Model nie jest w stanie wykryć nagłego wprowadzenia represji politycznych, dopóki działania te nie przełożą się na pogorszenie twardych wskaźników makroekonomicznych, co zazwyczaj następuje z opóźnieniem. Algorytm identyfikuje potencjał państwa do utrzymania standardów demokratycznych, lecz nie uwzględnia czynnika woli politycznej, która może ten potencjał ograniczać. Uczenie maszynowe w tym zastosowaniu skutecznie diagnozuje fundamenty strukturalne państwa, ale wykazuje ograniczoną czułość na decyzje polityczne elit rządzących.

Mimo że teoria modernizacji zakłada korelację rozwoju gospodarczego z demokracją, niniejsze badanie wskazuje na konieczność bardziej zniuansowanego podejścia. Zmienne takie jak PKB per capita czy średnia liczba lat edukacji, choć istotne w rankingu ważności cech, mają mniejszy wpływ na wynik niż profile historyczne.

Analiza zależności nieliniowych wykazała, że wzrost zamożności generuje wzrost poziomu wolności jedynie do określonego pułapu, co wskazuje na efekt nasycenia. Oznacza to, że wskaźniki społeczno-ekonomiczne działają przede wszystkim jako zabezpieczenie przed destabilizacją państwa, nie stanowią jednak gwarancji utrzymania ustroju demokratycznego.

Podsumowanie

Celem niniejszej pracy inżynierskiej było zaprojektowanie, implementacja oraz ewaluacja modelu uczenia maszynowego zdolnego do prognozowania poziomu przestrzegania praw człowieka w oparciu o wskaźniki społeczno-ekonomiczne. Przeprowadzone eksperymenty porównawcze wykazały wyższość modeli nieliniowych nad klasycznymi metodami statystycznymi.

Analiza wyników pozwoliła jednak na zidentyfikowanie istotnych ograniczeń metod czysto ilościowych w naukach społecznych. Opracowany model z wysoką precyzją identyfikuje długofalowe trendy oraz strukturalną zdolność państw do utrzymywania standardów praw człowieka. Jego główną zaletą jest możliwość oceny, czy dane państwo posiada fundamenty demograficzne i ekonomiczne niezbędne do funkcjonowania kraju jako wolnego. Główne wyzwanie stanowi natomiast detekcja nagłych wstrząsów władzy. Metodologię prognozowania przyszłości praw człowieka należy zatem rozszerzyć o analizę możliwych zdarzeń politycznych. Takie podejście pozwoliłoby na uzupełnienie prognoz opartych na wskaźnikach rozwoju o detekcję gwałtownych zwrotów autorytarnych, które w krótkim okresie mogą odchylać trajektorię państwa od jego strukturalnego potencjału.

Realizacja niniejszego projektu stanowi dowód na to, że wykorzystanie sztucznej inteligencji może stanowić wartościowe uzupełnienie tradycyjnych metod politologicznych, dostarczając obiektywnych, liczbowych ram do analizy przyszłości naruszeń praw człowieka.

Podczas przygotowywania niniejszej pracy autor korzystał z narzędzia OpenAI w celu korekty językowej – poprawy gramatyki, udoskonalenia sformułowań oraz zwiększenia ogólnej przejrzystości tekstu. Po użyciu tego narzędzia autor dokonał przeglądu i redakcji treści według potrzeb oraz ponosi pełną odpowiedzialność za treść opublikowanego artykułu.

Literatura

[1] Lipset. Some social requisites of democracy: Economic development and political legitimacy. *American Political Science Review*, 53:69–105, 1959.

[2] Zgromadzenie Ogólne ONZ. Powszechna deklaracja praw człowieka, 1948. Przyjęta 10 grudnia 1948, Paryż.

[3] Freedom House. Our History, 2025. Dostęp: 13.11.2025, `https://freedomhouse.org/about-us/our-history`.

[4] Ward i in. The perils of policy by p-value: Predicting civil conflicts. *Journal of Peace Research*, 47(4):363–375, 2010.

[5] Michael Colaresi and Zuhaib Mahmood. Do the robot: The impact of automated text analysis on human rights measurement. *Journal of Peace Research*, 54(2):193–207, 2017.

[6] O'Neill i in. The roads ahead: Narratives for shared socioeconomic pathways describing world futures in the 21st century. *Global Environmental Change*, 42:169–180, 2017.

[7] Freedom House. Country and Territory Ratings and Statuses, 1973-2025, 2025. Dostęp: 13.11.2025, `https://freedomhouse.org/report/freedom-world`.

[8] United Nations, Department of Economic and Social Affairs, Population Division. World population prospects 2024: Summary of results, 2024. Dostęp: 13.11.2025, `https://population.un.org/wpp/`.

[9] Gapminder Foundation. Gdp per capita in constant ppp dollars (v31), 2024. Dostęp: 13.11.2025, `https://www.gapminder.org/data/documentation/gd001/`.

[10] K.C. i in. Updating the shared socioeconomic pathways (ssps) global population and human capital projections, 2024. `https://pure.iiasa.ac.at/19487`.

[11] JetBrains. Pycharm: The python ide for professional developers, 2025. Dostęp: 13.11.2025, `https://www.jetbrains.com/pycharm/`.

[12] Python Software Foundation. Python language reference, version 3.12, 2024. Dostęp: 13.11.2025, `https://www.python.org/`.

[13] Harris i in. Array programming with NumPy, 2020. Dostęp: 13.11.2025, `https://numpy.org/`.

[14] The pandas development team. pandas-dev/pandas: Pandas, 2025. Dostęp: 13.11.2025, `https://pandas.pydata.org/`.

[15] Virtanen i in. SciPy 1.0: Fundamental algorithms for scientific computing in python, 2020. Dostęp: 13.11.2025, https://scipy.org/.

[16] Seabold and Perktold. statsmodels: Econometric and statistical modeling with python, 2010. Dostęp: 13.11.2025, https://www.statsmodels.org/.

[17] Jordahl i in. geopandas/geopandas: v1.0.1, 2024. Dostęp: 13.11.2025, https://geopandas.org/.

[18] Stadler. country_converter: Convert country names between different classifications and coding schemes, 2024. Dostęp: 13.11.2025, https://github.com/konstantinstadler/country_converter.

[19] Hunter. Matplotlib: A 2d graphics environment, 2007. Dostęp: 13.11.2025, https://matplotlib.org/.

[20] Waskom. seaborn: statistical data visualization, 2021. Dostęp: 13.11.2025, https://seaborn.pydata.org/.

[21] Pedregosa i in. Scikit-learn: Machine learning in Python, 2011. Dostęp: 13.11.2025, https://scikit-learn.org/.

[22] Chen and Guestrin. XGBoost: A scalable tree boosting system, 2016. Dostęp: 13.11.2025, https://xgboost.readthedocs.io/.

[23] Akiba i in. Optuna: A next-generation hyperparameter optimization framework, 2019. Dostęp: 13.11.2025, https://optuna.org/.

[24] Lundberg and Lee. A unified approach to interpreting model predictions, 2017. Dostęp: 13.11.2025, https://shap.readthedocs.io/.

[25] Sabrina P. Ramet. *The three Yugoslavias: State-building and legitimation, 1918-2005*. Indiana University Press, 2006.

[26] Freedom House. *Freedom in the World: The Annual Survey of Political Rights and Civil Liberties (Annual Reports 1993–1998)*. Freedom House, New York, 1993–1998.

[27] World Bank. Gdp per capita (current us$) - liechtenstein, switzerland, 2024. Dostęp: 13.11.2025, https://data.worldbank.org/indicator/NY.GDP.PCAP.CD.

[28] IIASA. Iiasa gdp 2023 projections, ssp database (shared socioeconomic pathways) - version 2.0, 2023. Dostęp: 13.11.2025, https://data.ece.iiasa.ac.at/ssp/.

[29] United Nations Development Programme. Human development report data center, 2024. Dostęp: 13.11.2025, https://hdr.undp.org/data-center/documentation-and-downloads.

[30] George A. F. Seber and Alan J. Lee. *Linear regression analysis*. John Wiley & Sons, 2003.

[31] Arthur E. Hoerl and Robert W. Kennard. Ridge regression: Biased estimation for nonorthogonal problems. *Technometrics*, 12:55–67, 1970.

[32] Leo Breiman, Jerome Friedman, Charles J. Stone, and Richard A. Olshen. *Classification and regression trees*. CRC press, 1984.

[33] Leo Breiman. Random forests. *Machine learning*, 45:5–32, 2001.

[34] Tianqi Chen and Carlos Guestrin. Xgboost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*, pages 785–794, 2016.

[35] David E. Rumelhart, Geoffrey E. Hinton, and Ronald J. Williams. Learning representations by back-propagating errors. *Nature*, 323:533–536, 1986.

[36] Christopher M. Bishop. *Neural networks for pattern recognition*. Oxford University Press, 1995.

[37] Xavier Glorot, Antoine Bordes, and Yoshua Bengio. Deep sparse rectifier neural networks. In *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*, pages 315–323, 2011.

[38] Diederik P. Kingma and Jimmy Ba. Adam: A method for stochastic optimization. *arXiv preprint arXiv:1412.6980*, 2014.

Załączniki

Załącznik A. *Trajektorie zmian statusu wolności w prognozach scenariuszy SSP*

Kraj	**Status 2024 r.**	**Status 2062 r.**	**Stabilność 2062 r.**	**Status 2100 r.**	**Stabilność 2100 r.**	**Scenariusze**
Albania	Częściowo Wolny	Wolny	Ryzyko ↓	Wolny	Ryzyko ↓	SSP1, SSP2, SSP3
Algeria	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2
Algeria	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Ryzyko ↑	SSP3
Angola	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Bahrain	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2
Bahrain	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP3
Bolivia	Częściowo Wolny	Wolny	Stabilny	Wolny	Ryzyko ↓	SSP1
Bolivia	Częściowo Wolny	Wolny	Ryzyko ↓	Wolny	Ryzyko ↓	SSP2
Brazil	Wolny	Częściowo Wolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↑	SSP1, SSP2
Brazil	Wolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP3
Brunei Darussalam	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP2, SSP3
Brunei Darussalam	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Ryzyko ↑	SSP1
Burundi	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1
Cambodia	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1, SSP2
Cameroon	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP2, SSP3
Cameroon	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1
Chad	Niewolny	Niewolny	Stabilny	Częściowo Wolny	Ryzyko ↓	SSP1
Chad	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP3
Congo Republic	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1, SSP2, SSP3
Cuba	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Ryzyko ↑	SSP1
Cuba	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP2
Cuba	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP3

Ciąg dalszy na następnej stronie

Kraj	Status 2024 r.	Status 2062 r.	Stabilność 2062 r.	Status 2100 r.	Stabilność 2100 r.	Scenariusze
Djibouti	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP2, SSP3
Djibouti	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP1
Dominican Republic	Częściowo Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Ryzyko ↓	SSP3
Ecuador	Częściowo Wolny	Wolny	Stabilny	Wolny	Stabilny	SSP1, SSP2
Ecuador	Częściowo Wolny	Wolny	Ryzyko ↓	Wolny	Ryzyko ↓	SSP3
Egypt	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1
Egypt	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP2
Egypt	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Ryzyko ↑	SSP3
El Salvador	Częściowo Wolny	Częściowo Wolny	Stabilny	Niewolny	Ryzyko ↑	SSP3
Eritrea	Niewolny	Niewolny	Stabilny	Częściowo Wolny	Ryzyko ↓	SSP1
Eswatini	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Ethiopia	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP1
Ethiopia	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP2
Fiji	Częściowo Wolny	Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↑	SSP1, SSP2
Fiji	Częściowo Wolny	Wolny	Ryzyko ↓	Wolny	Ryzyko ↓	SSP3
Gabon	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Guinea	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1
Guinea	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP2
Guinea	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP3
Haiti	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Hungary	Częściowo Wolny	Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↑	SSP2
Iraq	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Kazakhstan	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Ryzyko ↑	SSP1, SSP2
Kuwait	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP2, SSP3

Ciąg dalszy na następnej stronie

Kraj	Status 2024 r.	Status 2062 r.	Stabilność 2062 r.	Status 2100 r.	Stabilność 2100 r.	Scenariusze
Kuwait	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1
Kyrgyzstan	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP1
Kyrgyzstan	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP2
Laos	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP1
Laos	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP2
Laos	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Ryzyko ↑	SSP3
Lesotho	Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Stabilny	SSP1, SSP2
Lesotho	Wolny	Częściowo Wolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↑	SSP3
Libya	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1
Libya	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP2
Libya	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP3
Malawi	Częściowo Wolny	Częściowo Wolny	Stabilny	Wolny	Ryzyko ↓	SSP1
Montenegro	Częściowo Wolny	Wolny	Ryzyko ↓	Wolny	Ryzyko ↓	SSP3
Namibia	Wolny	Wolny	Stabilny	Częściowo Wolny	Ryzyko ↑	SSP1
Namibia	Wolny	Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↑	SSP2
Nauru	Wolny	Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↑	SSP2
Nepal	Częściowo Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Ryzyko ↓	SSP1
North Korea	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP2
North Macedonia	Częściowo Wolny	Wolny	Ryzyko ↓	Wolny	Ryzyko ↓	SSP1, SSP2
North Macedonia	Częściowo Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Ryzyko ↓	SSP3
Oman	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Qatar	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Rwanda	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1, SSP2
Saudi Arabia	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP2

Ciąg dalszy na następnej stronie

Kraj	Status 2024 r.	Status 2062 r.	Stabilność 2062 r.	Status 2100 r.	Stabilność 2100 r.	Scenariusze
Saudi Arabia	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP3
Senegal	Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Stabilny	SSP1
Senegal	Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Ryzyko ↓	SSP2
Senegal	Wolny	Częściowo Wolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↑	SSP3
Solomon Islands	Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Ryzyko ↓	SSP2
Somalia	Niewolny	Niewolny	Stabilny	Częściowo Wolny	Ryzyko ↓	SSP2, SSP3
Somalia	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1
Sudan	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP2, SSP3
Sudan	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Stabilny	SSP1
Syria	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Stabilny	SSP1, SSP2
Syria	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP3
Tanzania	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1
Thailand	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3
Timor-Leste	Wolny	Częściowo Wolny	Ryzyko ↑	Wolny	Ryzyko ↓	SSP1, SSP3
Timor-Leste	Wolny	Częściowo Wolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↑	SSP2
Turkmenistan	Niewolny	Niewolny	Ryzyko ↑	Częściowo Wolny	Ryzyko ↓	SSP1
Türkiye	Niewolny	Częściowo Wolny	Stabilny	Częściowo Wolny	Stabilny	SSP1
Türkiye	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP2
Türkiye	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP3
Uganda	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP1
Uganda	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Ryzyko ↓	SSP2
Uganda	Niewolny	Częściowo Wolny	Ryzyko ↓	Niewolny	Stabilny	SSP3
United Arab Emirates	Niewolny	Niewolny	Stabilny	Częściowo Wolny	Ryzyko ↓	SSP1, SSP2
Zimbabwe	Niewolny	Częściowo Wolny	Ryzyko ↓	Częściowo Wolny	Stabilny	SSP1, SSP2, SSP3

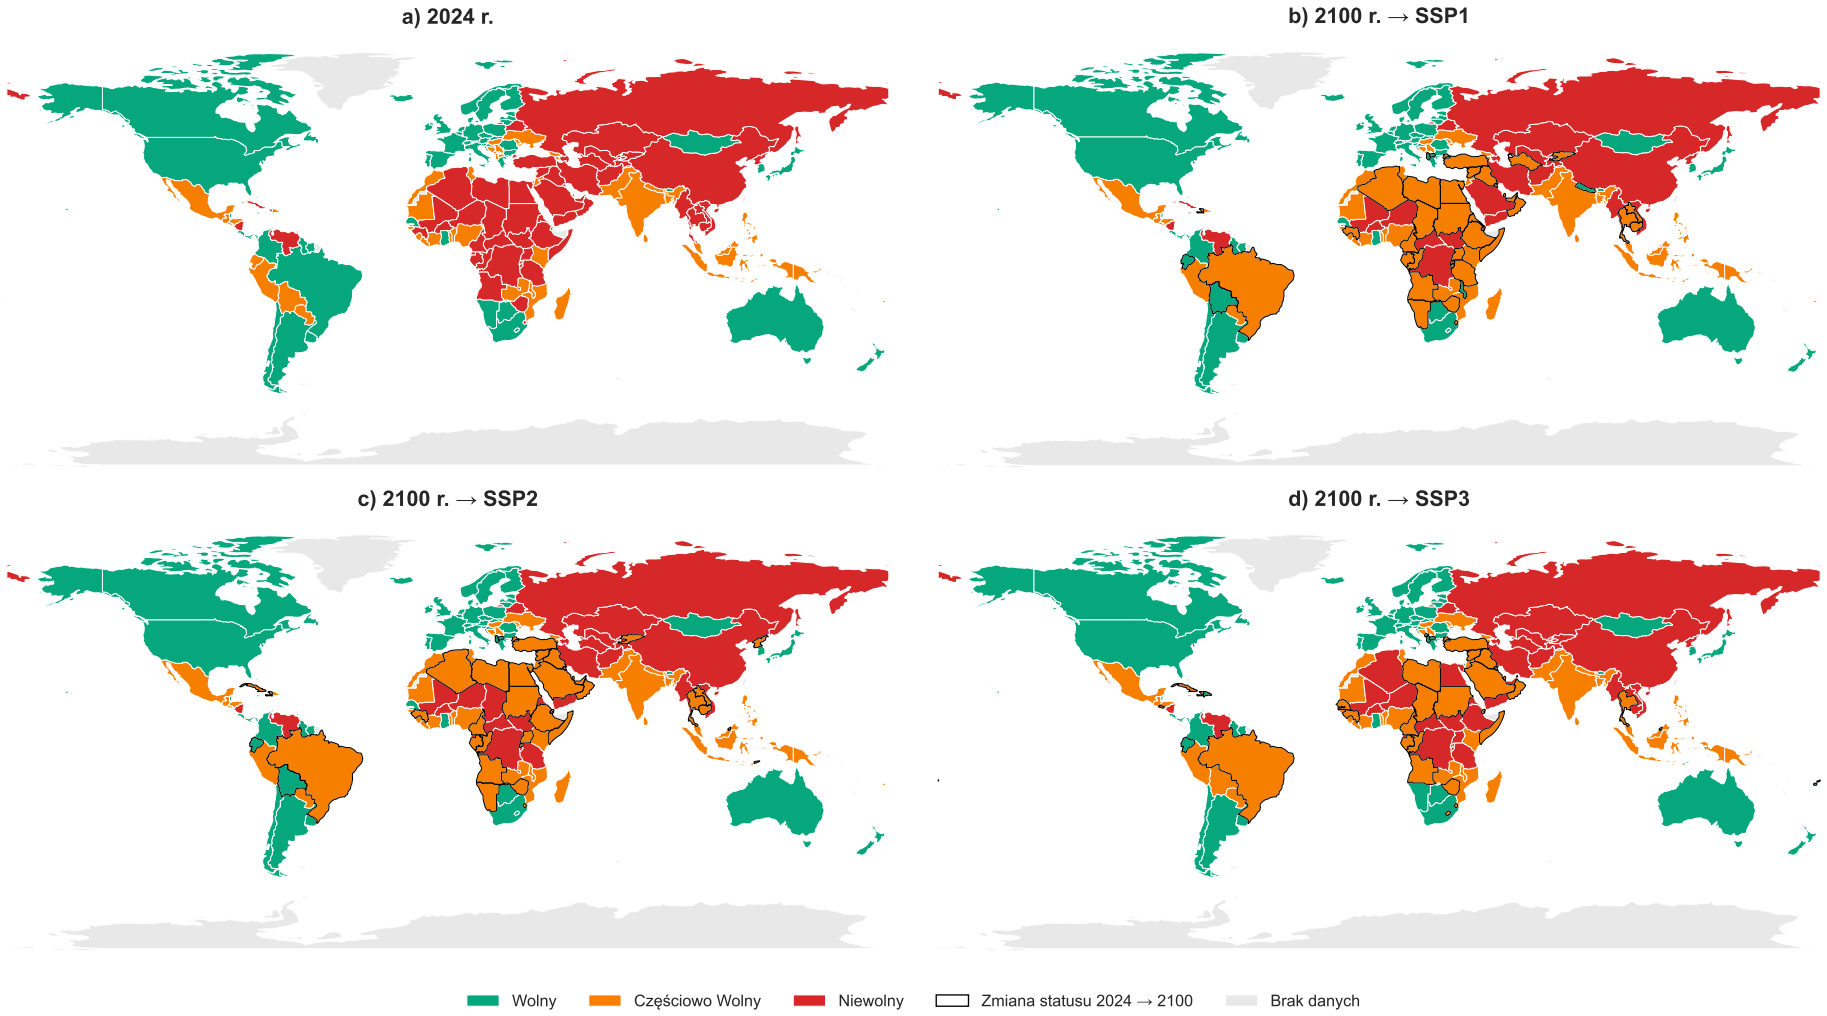

Załącznik B. *Porównanie globalnego stanu wolności w 2024 roku oraz projekcji na rok 2100 w oparciu o scenariusze SSP1, SSP2 i SSP3.*